수소 반응계 NN 연구
무엇을 바꿨고, 무엇을 확인했는가

기준 ANN → 조건부 DeepONet → 물리 벌점 → 전처리 → 시간·다중 스텝 → 일반 ANN

핵심 질문

한 스텝의 작은 오차를 줄이면
10 ms 자기 예측도 정확해지는가?

연구 미팅용 · 본문 23장 + 부록 8장 · 2026-11-06 KST

자료 기준: bw ad8c537 · 최신 일반 ANN 장기 결과까지 포함

계산의 안정성은 일부 개선됐지만, 넓은 정확도는 아직 부족하다

모든 수치는 저장된 test 결과 기준이며, 테스트 조건은 18개다.

보정 없는 정확도 통과 조건

1 / 18

세 모델 설정이 통과했지만
모두 같은 IC39였다.

최신 일반 ANN 실험

0 / 18

단일·다중 스텝, 단기·장기
모두 정확도 통과는 없었다.

결과를 읽는 원칙

두 지표

완주 수와 정확도 통과 수,
raw와 repaired를 구분한다.

정확도 통과: full 10 ms + T·8반응종 모두 NRMSE ≤ 0.1. N2는 별도 점검했다.

한 번에 다 바꾸지 않고, 실패 원인을 나누어 확인했다

왜 했는가 → 무엇을 바꿨는가 → 무엇이 남았는가

main 기준

ANN 10/100 평균

앙상블 크기만으로 해결되지 않음

bw: 구조

P → T/P → T/P/phi

조건 분리·혼합과 장기 학습 비교

bw: 손실

원소 보존 soft constraint

λ를 늘려도 raw 정확도 확대 실패

bw: 전처리

Box-Cox γ 6개

온도 점수와 화학종 점수의 차이 확인

bw: 시간 학습

간격 τ + 다중 스텝 K

학습과 실제 자기 예측의 차이 축소 시도

bw: 일반 ANN

K1 대 K1→64

DeepONet과 분리해 효과 재확인

main의 연구를 bw의 신규 성과로 합산하지 않았다. 단기·장기·재사용 체크포인트도 구분했다.

NN은 반응률이 아니라, 정규화된 상태의 증분을 예측한다

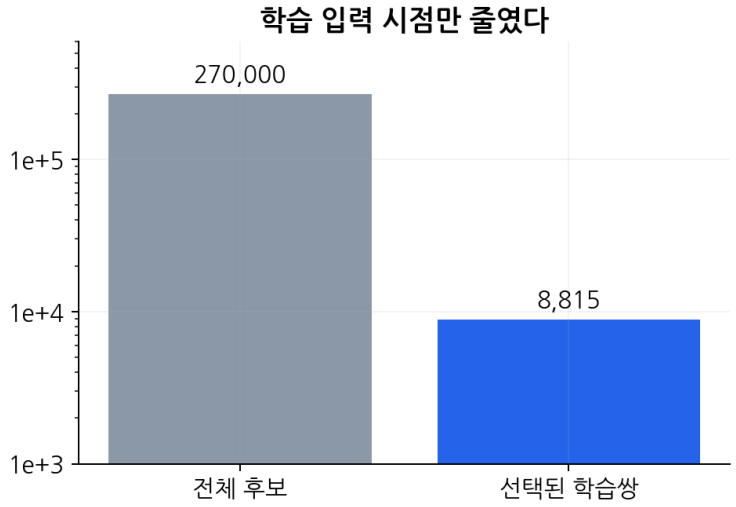
Cantera의 정압·단열 H2/air 반응계를 2 us 간격으로 전진시킨다.

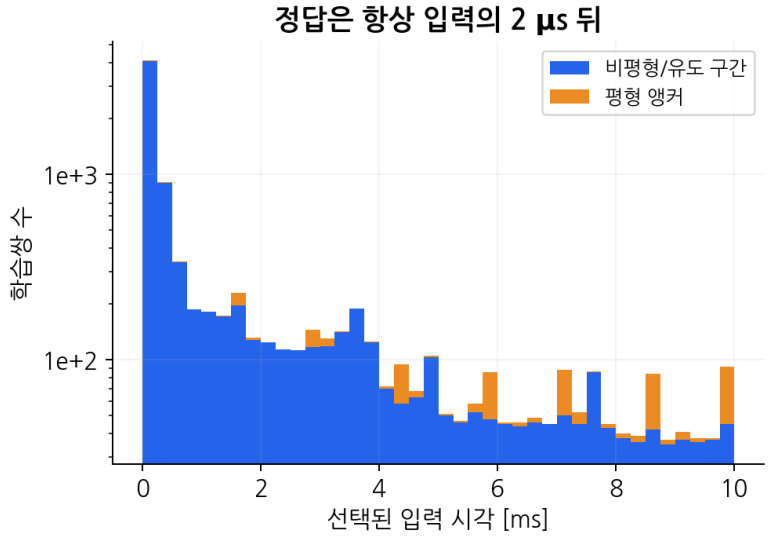
항목	공통 기준
대상	h2o2.yaml 기반 H2/air · 9화학종 · 28반응
조건	90 IC: T 900-1600 K · P 1-5 atm · phi 0.5-2
상태 / 입력	T + Y9 / 현재 상태 + 압력 (일반 ANN 입력 11개)
출력	Δz = 표준화된 다음 상태 − 표준화된 현재 상태
실제 평가	2 us × 5,000회 자기 예측 = 10 ms

한 번의 상태 정확도와, 5,000회 되먹인 궤적의 정확도는 다른 문제다.

학습 시작점은 줄였지만, 정답 간격은 2 us로 유지했다

trajectory 단위 train 54 / validation 18 / test 18 분할을 고정했다.





평형 과대표집 완화

선택된 평형 앵커는 376개 / 8,815개.
조밀한 원자료의 평형 비중은 약80.5%였다.

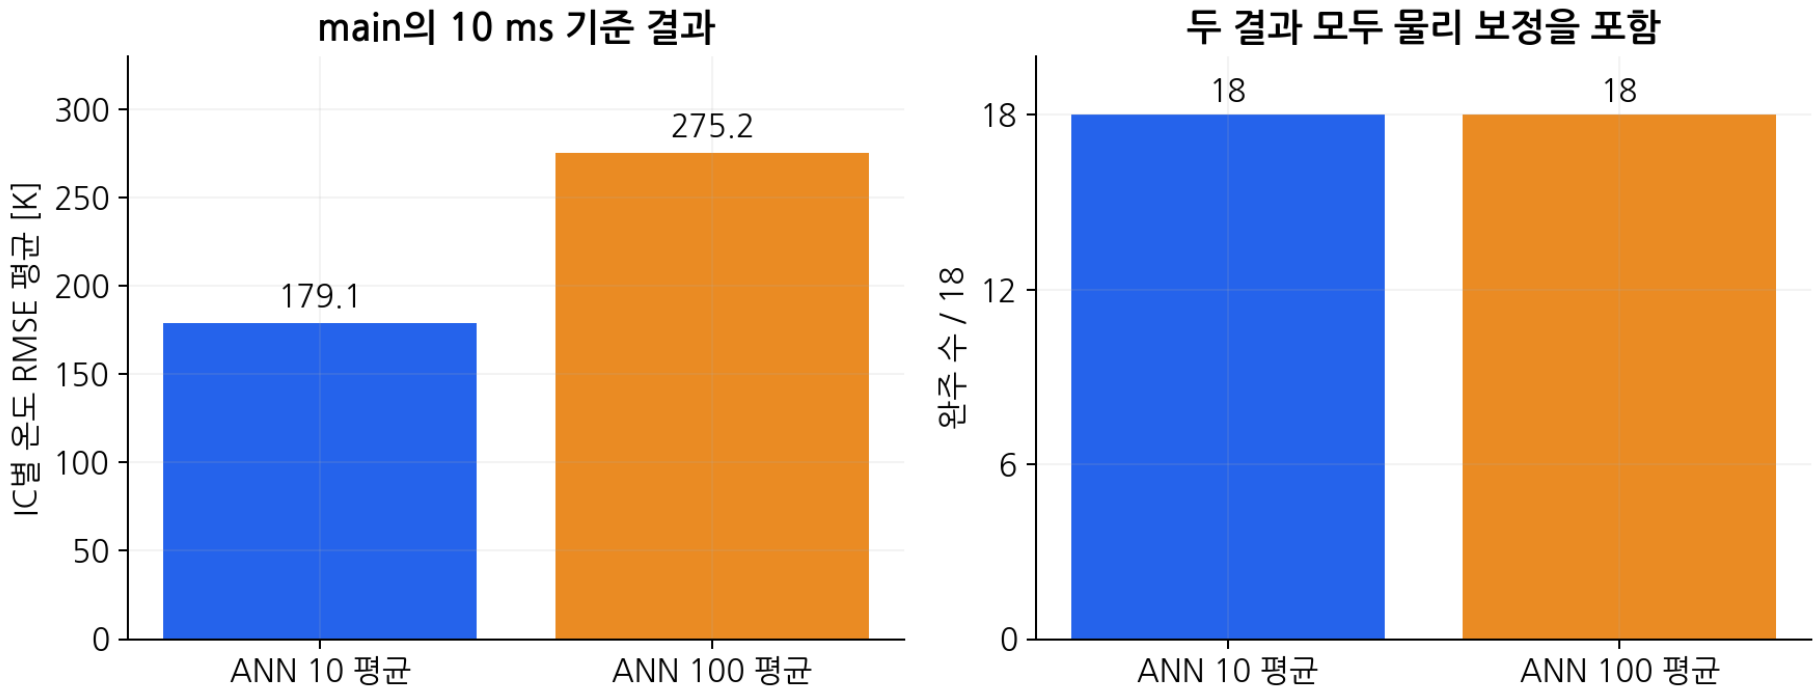
변환 후 train 통계로 표준화

T/1000, Y^γ/γ, log(P)를 사용한다.
γ 실험에서도 분할과 시작점은 유지했다.

학습 입력을 고르는 것과 rollout 시간 간격을 바꾸는 것은 구분했다.

ANN을 10개에서 100개로 늘려도 오차가 줄지 않았다

이 결과는 main에 이미 있던 물리 보정 포함 앙상블 비교다.



결정: 앙상블 크기를 키우는 대신 입력 구조·학습 목표·전처리를 차례로 살펴본다.

압력·온도·당량비를 분리해서 넣는 DeepONet을 비교했다

모두 같은 현재 상태에서 다음 상태 증분을 만드는 유한 차원 조건부 모델이다.

모델	Branch 입력	Trunk 입력	파라미터
일반 ANN	현재 T·Y9 + P를 MLP에 함께 입력	없음	9,738
P-only DeepONet	현재 T·Y9	현재 log(P)	9,719
T/P DeepONet	현재 Y9	현재 T, log(P)	9,687
T/P/phi DeepONet	현재 Y9	현재 T, log(P), 초기 phi	9,719
ANN + Deep 혼합	같은 현재 상태 → ANN10 + Deep10	20개 후보 평균	별도 학습 없음

DeepONet이라는 구조 이름만으로 임의 함수·새 반응계에 대한 일반화가 검증된 것은 아니다.

학습을 늘리고 phi를 넣어도, raw 정확도는 일부 조건에 머물렀다

아래는 초기 구조 실험의 long 결과다. 이후 γ 실험과 중복 합산하지 않는다.

장기 평가 설정	raw 완주 / 18	raw 정확도 통과 / 18
ANN10 (기준 모델 재사용)	2	0
P-only10	6	0
ANN10 + P-only10	9	0
T/P10	12	1 (IC39)
ANN10 + T/P10	6	0
T/P/phi10	7	0
ANN10 + T/P/phi10	11	0

다음 질문: MSE에 원소 보존 벌점을 더하면 자기 예측의 이탈을 줄일 수 있을까?

Soft constraint는 학습 벌점이고, rollout 물리 보정과 다르다

실제 구현은 다음 상태의 원소량 오차에 대한 L1 벌점이다.

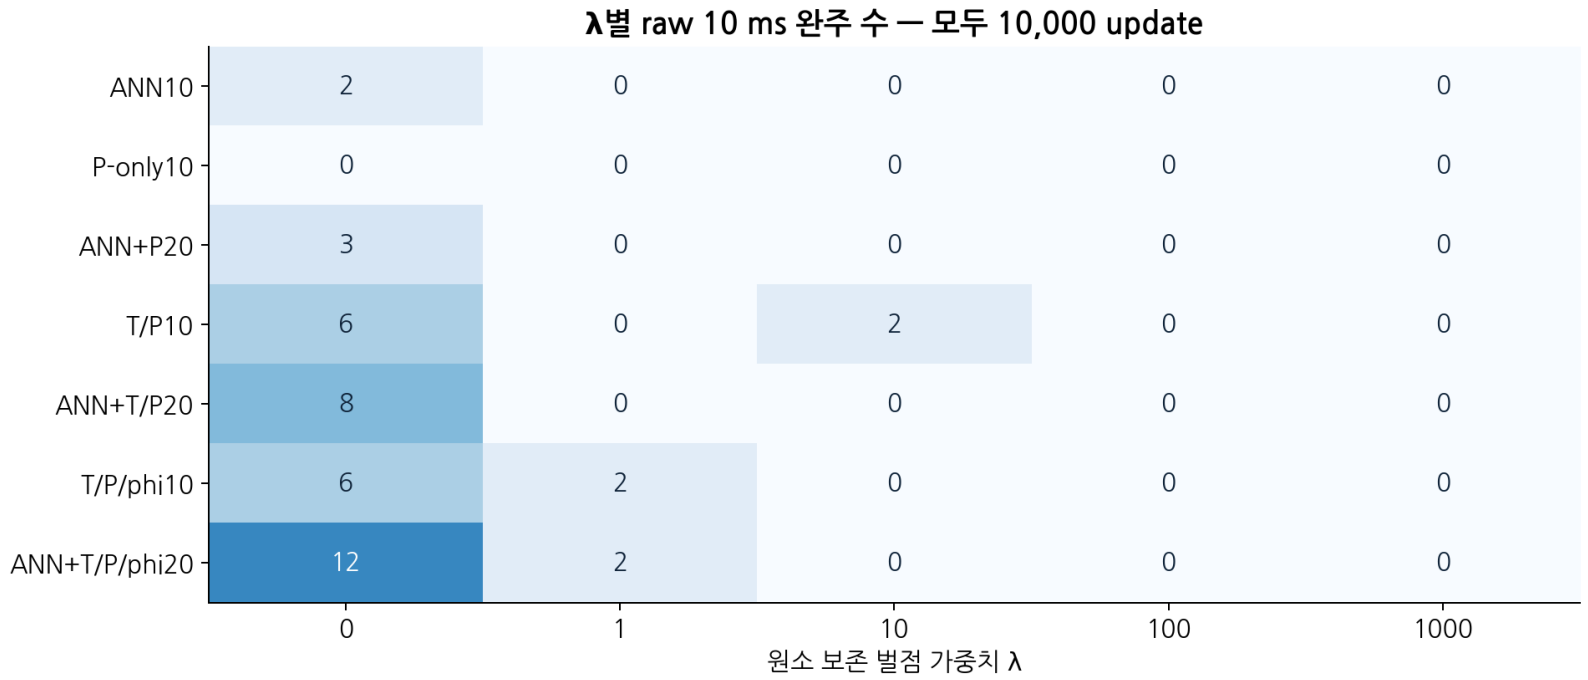
$$\text{Loss} = \text{MSE}(\Delta z_{pred}, \Delta z_{true}) + \lambda \cdot \text{mean}\left[\Sigma \left| A \cdot (Y_{pred} - Y_{true,next}) \right| \right]$$

구분	학습 soft constraint	평가 repaired
작동 시점	역전파할 손실에 추가	예측한 후보 상태를 매 스텝 수정
물리 정보	H/O/N 원소량 차이	비음수·원소 투영·엔탈피 온도 보정
이번 비교	λ=1, 10, 100, 1000	raw와 별도 평가·별도 표기

신경망 출력은 계속 상태 증분이다. 반응률을 직접 출력하도록 바꾼 실험은 아니다.

λ를 키우거나 더 오래 학습해도 raw 정확도 통과는 늘지 않았다

γ=.1 고정 · 4개 학습 계열 + 3개 혼합 평가 · short=10,000 update



추가 학습도 수행

λ=10: 40개 연장
λ=1/100/1000: 120개 연장

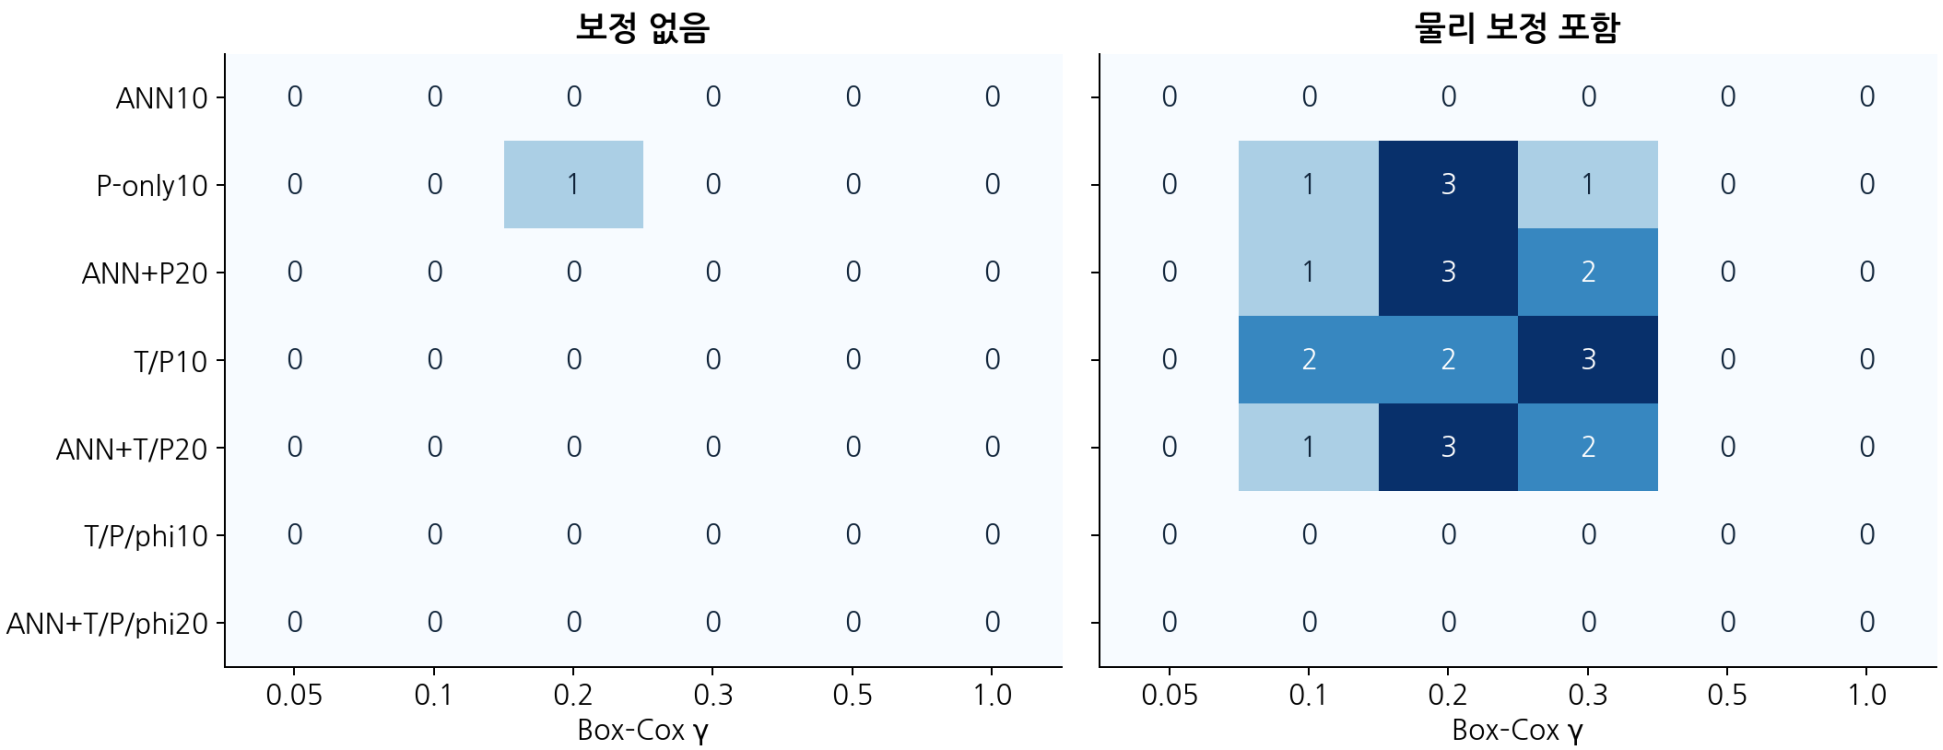
관찰과 다음 결정

새 soft 모델의 raw 정확도 통과 0.
이후 soft 항을 빼고 γ만 바꿨다.

큰 λ는 이 설정에서 완주도 악화시켰다. 장기 시간상한 종료를 평탄 도달로 부르지 않았다.

γ에 따라 성능이 달랐지만, 보정 없는 정확도는 넓어지지 않았다

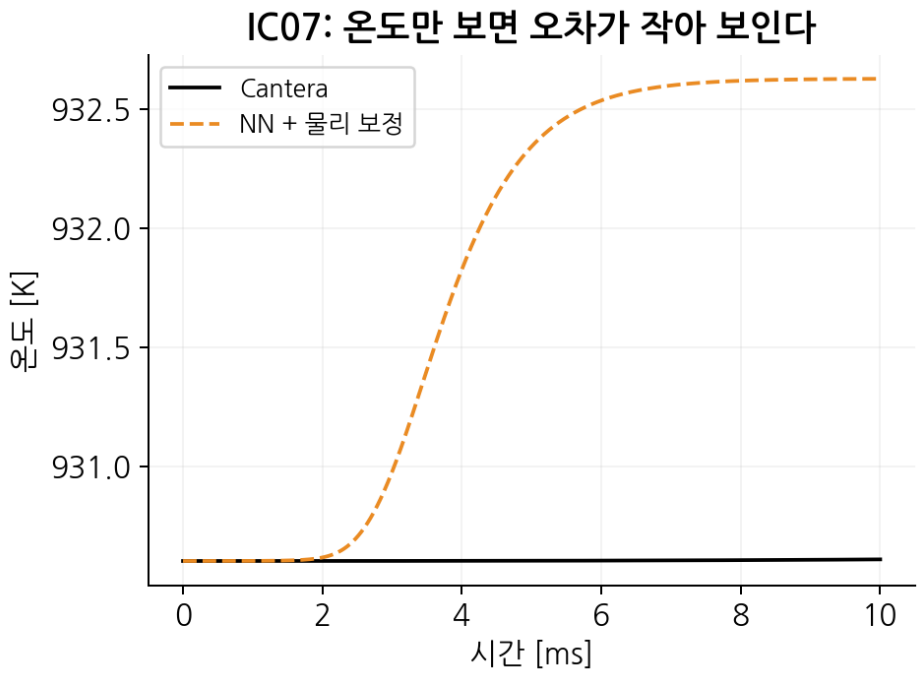
γ=.05/.1/.2/.3/.5/1 · 4계열×10개 · MSE만 사용

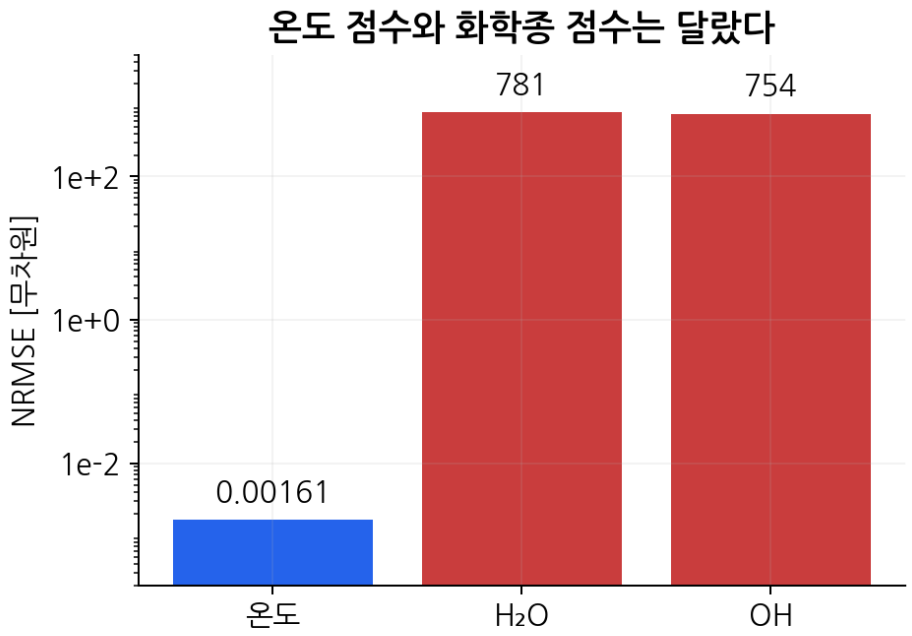


각 칸은 joint9 정확도 통과 수 / 18 (완주 수가 아님). long: 평탄 0 / 시간상한 240.

온도 NRMSE가 작아도, 반응종이 잘 맞는 것은 아니었다

IC07 · γ=.2 · ANN+P 장기 · 물리 보정 포함 예측





Cantera ΔT≈0.0068 K, NN ΔT≈2.02 K. T NRMSE≈0.00161, H2O≈781, OH≈754.

물리 보정은 완주를 도와주지만, 반응 속도까지 보장하지 않는다

raw = 모델 후보를 그대로 사용 / repaired = 아래 절차를 포함한 시스템 결과

1

역변환 영역 clipping

2

비음수 · 원소량 투영

3

엔탈피로 온도 복원

4

유효 후보 평균 후 재보정

완주가 의미하는 것

10 ms까지 유효한 상태로 계산이 이어졌다는 뜻이다.

완주만으로 말할 수 없는 것

Cantera와의 정확도, 점화 시각, 미량 화학종 정확도를 보장하지 않는다.

보정 없는 통과 설정은 세 개였고, 고유 조건은 IC39 하나였다

저장된 10 ms test raw 기록을 감사하고 최신 일반 ANN 결과를 추가 확인했다.

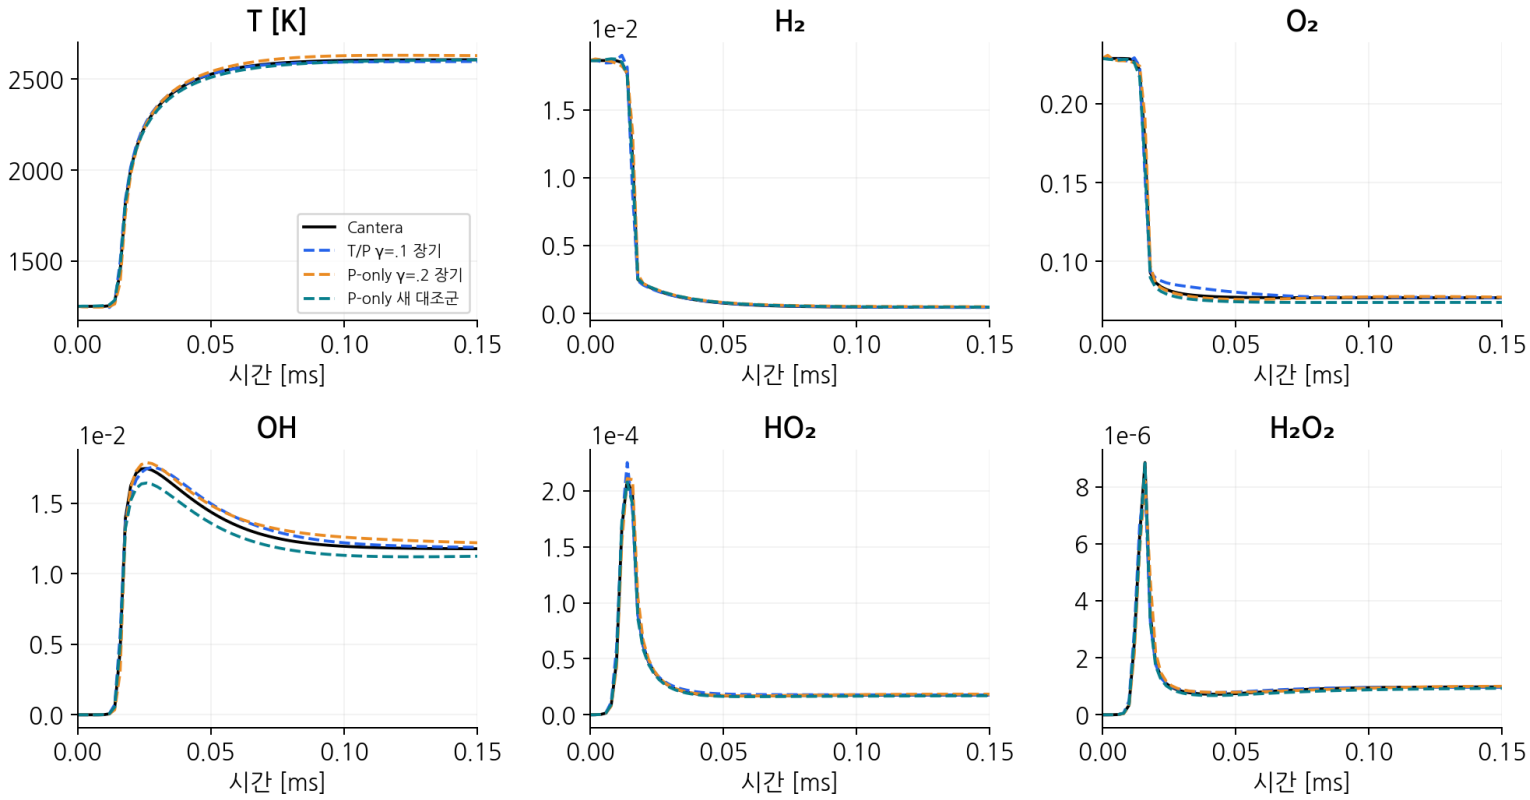
raw 설정 (모두 IC39)	max NRMSE 10 ms	초기 0.1 ms max
T/P Deep10 · γ=.1 · 장기	0.0743	0.0975
P-only Deep10 · γ=.2 · 장기	0.0759	0.1347 (문턱 초과)
P-only Deep3 · γ=.2 · 새 장기 대조	0.0861	0.0558

$$\mathrm{NRMSE} = \mathrm{RMSE}(\mathrm{Cantera}, \mathrm{NN}) / \mathrm{RMS}(\mathrm{Cantera})$$

무차원 비율이며 %가 아니다. N2를 포함해도 세 통과 설정은 동일하다. 정확도 문턱은 사후 진단용이다.

IC39의 점화 구간은 맞췄지만, 다른 17조건으로 확장되지 않았다

T0=1250.05 K · P0=2.297 atm · phi0=.646 · 보정 없는 세 설정

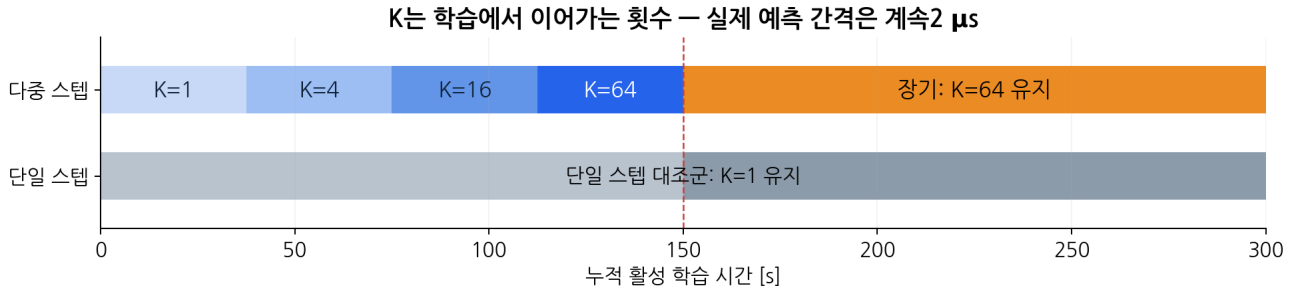


각 패널은 0-0.15 ms 확대. 세 설정 모두 질량·원소량 drift가 남아 있어 물리 보존 인증은 아니다.

시간 간격을 바꾸는 모델과, 여러 번 되먹이며 학습하는 모델을 나눴다

둘 다 기존 DeepONet 기반으로 시작했으며, 모든 최종 평가는 2 us 고정이다.

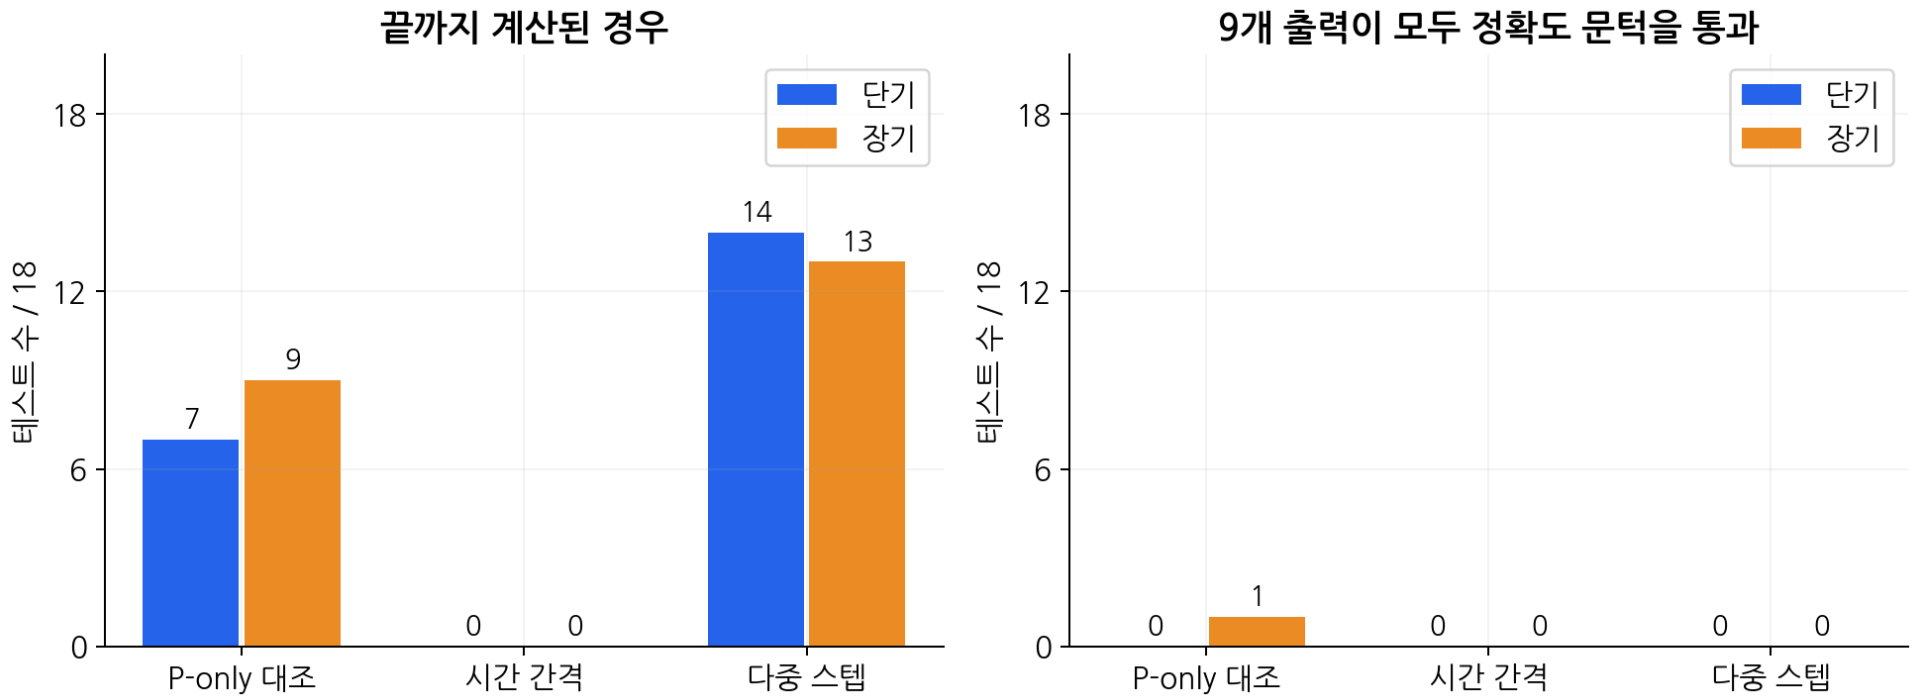
접근	바꾼 것	추가 정답 / 실제 평가
시간 간격 DeepONet	trunk = 앞으로의 간격 tau	2/4/8/16 us 정답 / 평가는 2 us
다중 스텝 DeepONet	2 us 예측을 K번 되먹인 loss	모든 중간 오차 / 평가는 2 us



기존 dense 정답을 재사용했다. 전체 시간장을 직접 출력하는 모델은 이번에 실행하지 않았다.

다중 스텝은 raw 완주를 늘렸지만, 새 정확도 통과는 없었다

seed11/22/33 각각 학습 · 아래는 3개 평균 · γ=.2 · 단기150초 + 장기최대150초/모델



시간 간격: 평탄 3/3이지만 raw 완주 0. repaired 정확도: 대조군 3→2, 새 두 방식은 0.

다중 스텝 효과를 일반 ANN에서도 별도 대조 실험했다

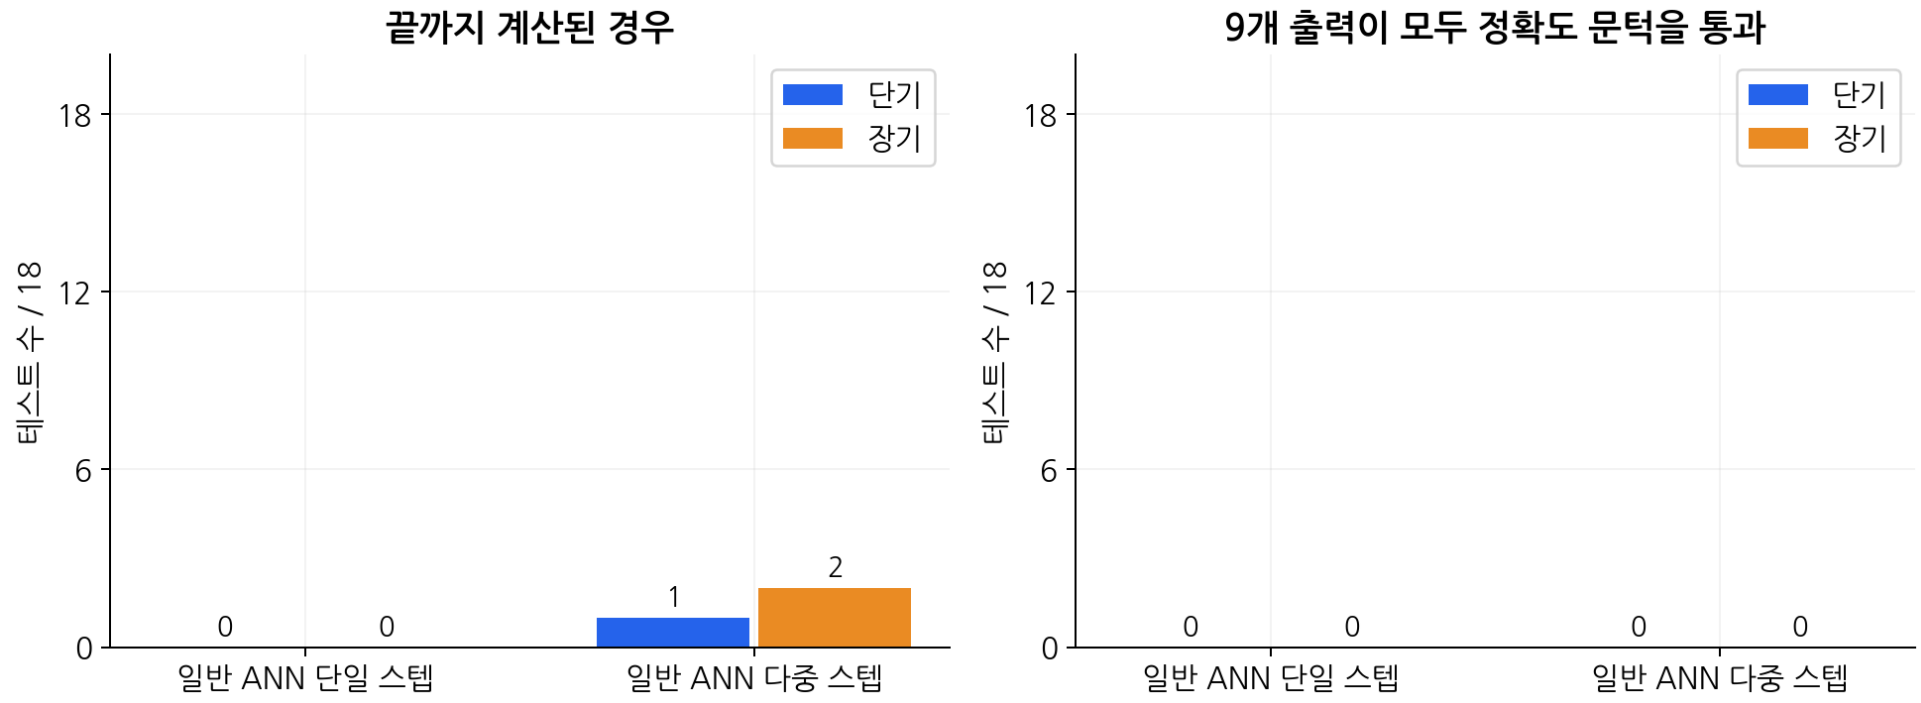
branch/trunk 없는 11→64→64→64→10 tanh MLP · 9,738 parameters

고정한 것	비교한 것
같은 seed 초기 가중치 · seed 11 / 22 / 33	단일 스텝 loss: K=1
같은 8,815개 시작점 · gamma=.2 · 배치512	다중 스텝 loss: K1→4→16→64
각 모델 단기150초 + 추가 최대150초	장기에서는 다중 스텝 K64 유지
가중치 + Adam 정확 복원	raw / repaired, seed별 / mean3 각각 평가

이번 “단기”는 10,000 update가 아니라 활성 학습 150초다. 동시간 비교에서 update 수는 달라진다.

일반 ANN도 다중 스텝에서 일부 더 완주했지만, 정확하지 않았다

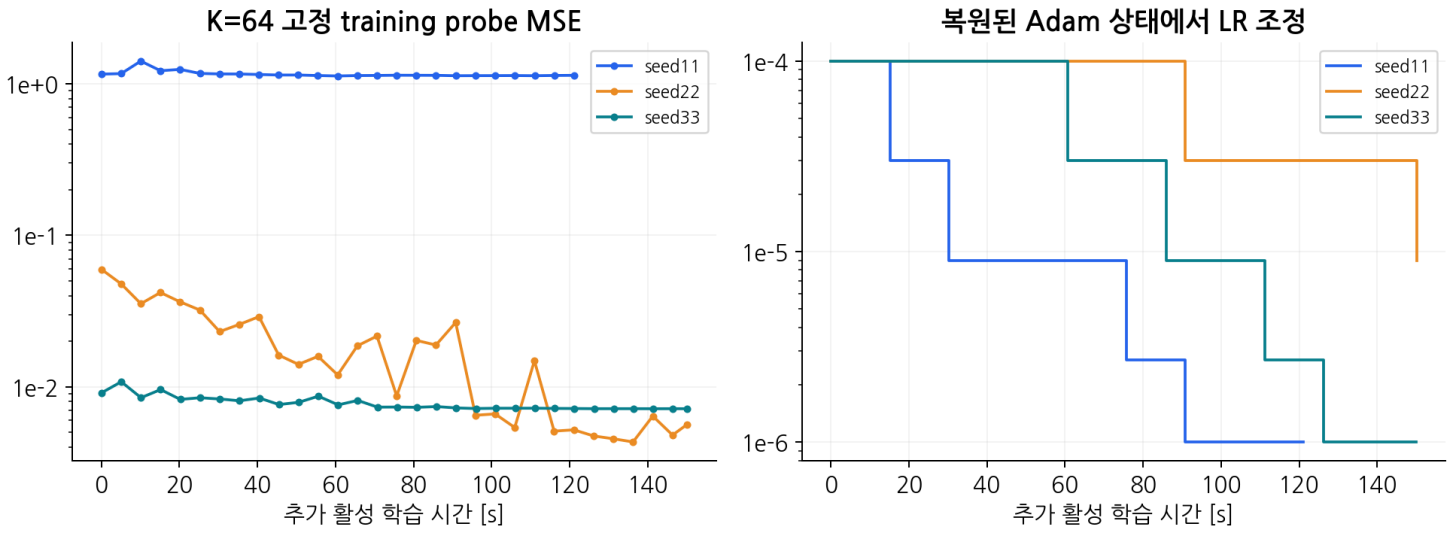
3개 평균 · raw 결과 먼저 · 정확도 동시 통과는 seed별로도 모두 0



repaired 완주: 단일 18→18, 다중 13→14. 두 방식의 정확도 통과는 단기·장기 모두 0.

학습 loss의 평탄과, 예측 결과의 정확도는 일치하지 않았다

일반 ANN 다중 스텝 · 고정 K64 training probe와 seed별 raw 완주

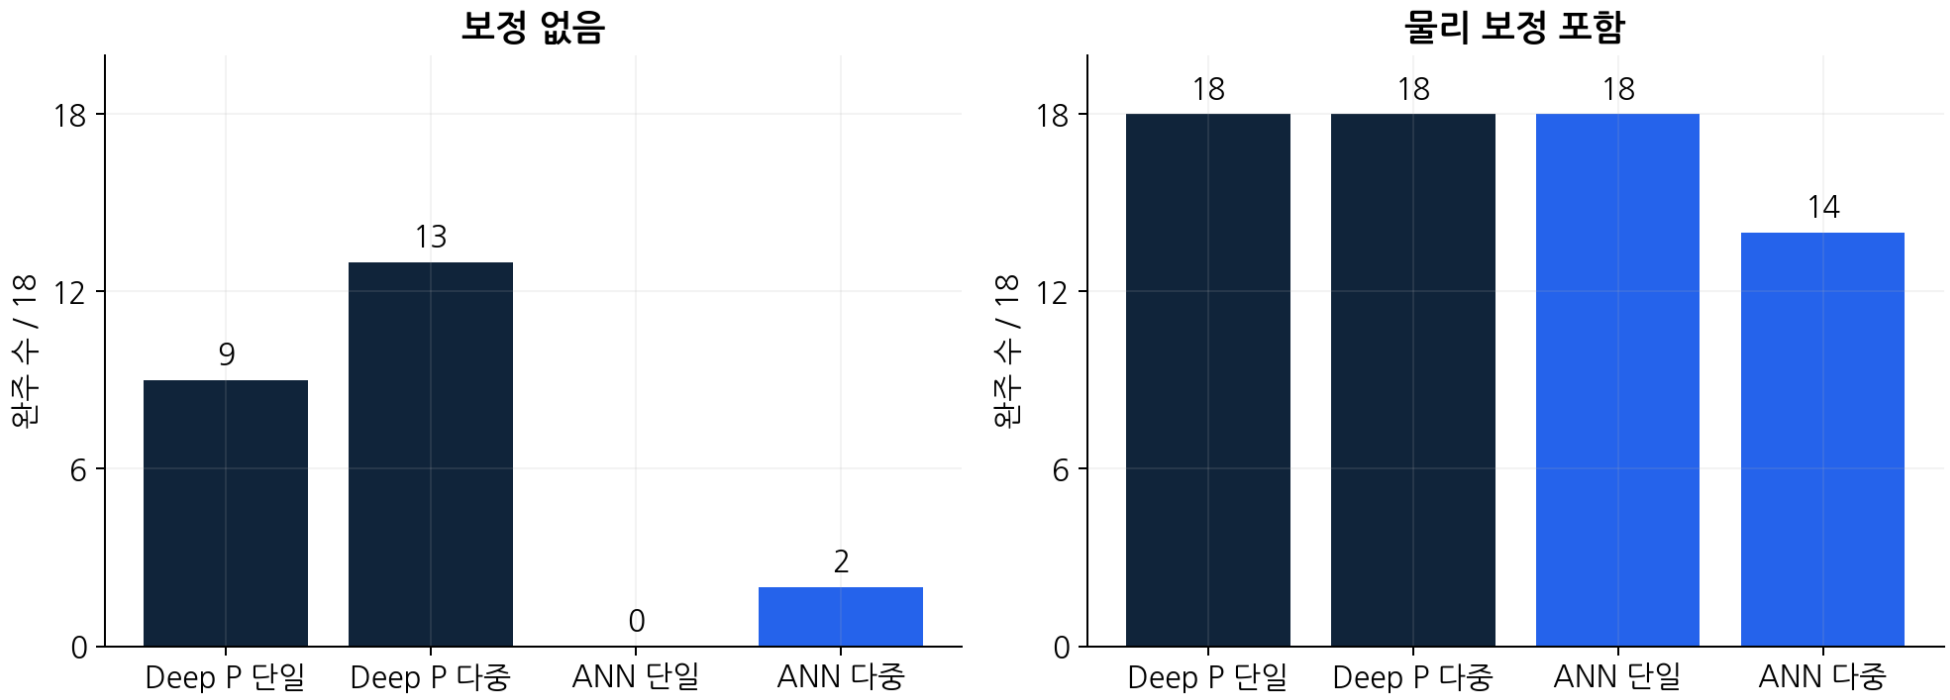


장기 raw	완주 / 18
seed11	0
seed22	9
seed33	7
mean3	2

일반 ANN 장기 종료: 평탄 1 / 시간상한 5. “loss 평탄”은 “10 ms가 정확함”을 뜻하지 않는다.

이 설정에서는 DeepONet 다중 스텝이 ANN보다 더 많이 완주했다

γ=.2 · 각 3seed 평균 · 단기150초 + 장기최대150초 · 같은 test18



정확도 통과(raw): Deep P 단일 1, 나머지 0. 여기의 막대는 완주 수다.

실험 결과와 계산 예산을 함께 남기는 파이프라인을 만들었다

관리형 클라우드 · 순차 학습 · checkpoint + Adam · 단기 게시 gate · 검증된 보고서

비교 가능하게 기록

고정 분할·시간 간격·정규화 · seed · 활성 학습 시간 · 종료 이유

결과를 추적 가능하게 보존

모델 / Adam / rollout / NRMSE CSV / 전체·점화 PDF / 검증 SHA

실행과 게시를 분리

단기 검증·커밋·원격 SHA 확인 후 장기 시작. 최신 ANN 장기도 게시 완료.

최신 일반 ANN 장기 게시: ad8c537 · 완료 모델 재학습이나 시간 예산 재시작 없이 정리했다.

다음 목표는 완주 수보다, 보정 없이 여러 조건에서 맞는 모델이다

아래는 실행한 결과가 아니라, 현재 관찰에 근거한 후속 제안이다.

관찰	다음에 분리해서 검증할 가설
K64에서 최적화 비용이 커짐	validation에서 K / loss 가중치 / 학습 시간 배분을 소규모 비교
작은 one-step MSE와 큰 rollout 오차	중간 궤적 오차 + 화학종별 스케일을 함께 점검
자기 예측 상태가 학습 분포에서 이탈	분포 이탈 진단 후 필요한 상태에만 정답 보강
보정은 보존을 돕지만 kinetics는 틀림	보존 구조와 반응 정확도를 별개로 검증

선택은 validation으로, 최종 확인은 새 holdout으로. 기존 test에서 좋은 사례만 고르지 않는다.

“단기”와 “장기”의 예산이 모든 단계에서 같지는 않다

행별로 독립 연구 범위와 재사용을 구분했다. 신규 모델 총합으로 단순 합산하지 않는다.

연구 단계	단기	장기 / 비교 단위
P-only / T-P / phi	각 구조 10개 · 기준 10k	각 후속 연구 전체 최대6시간
Soft λ10	4계열×10 = 40개 · 10k	40개 연장 · 연구 전체 최대6시간
Soft λ1/100/1000	3×4계열×10 = 120개 · 10k	120개 연장 · 연구 전체 최대6시간
Box-Cox γ 6개	240개 기준점 (신규200/재사용40)	240개 · 추가150활성초/모델
시간 DeepONet	3방식×3seed = 9개 · 150초	9개 정확 복원 · 최대150초 추가
일반 ANN	2방식×3seed = 6개 · 150초	6개 정확 복원 · 최대150초 추가

4개 학습 계열 = ANN / P-only / T-P / T-P-phi. 혼합 평균은 별도 학습 모델을 만들지 않는다.

전처리 → 증분 예측 → 물리 상태 복원 → 자기 예측

시간마다 현재 상태를 다시 변환한다. “다음 상태”와 “증분”을 혼동하지 않는다.

1. 변환	E(T,Y) = [T/1000, Y^γ/γ]
2. 표준화	z = (E − μ_train) / σ_train
3. 증분 정답	Δz_true = z(t + 2 us) − z(t)
4. 다음 상태	z_pred,next = z_current + NN(current, condition)
5. 다중 스텝	L_K = mean_{k=1⋯K} MSE(z_pred,k, z_true,k)

NRMSE는 이 표준화 공간의 loss가 아니라, 복원된 물리 상태와 Cantera를 비교한 지표다.

과거 γ 선택은 보정 포함 온도 기준이며, 전체 화학종 최적은 아니다

validation 완주 수 최대 → 공통 완주 IC의 온도 NRMSE 중앙값 최소 → 동률이면 낮은 γ

평가 설정	선택 γ
ANN10	.1
P-only10 / ANN+P20	.2
T/P10 / ANN+T/P20	.3
T/P/phi10 / ANN+T/P/phi20	.2

현재 발표의 정확도 재점검

T + 8반응종을 각각 확인한다.
온도 선택과 전체 화학종 평가는 다르다.

아직 하지 않은 것

λ×γ 전체 factorial 비교,
일반 ANN 다중 스텝의 γ 최적화.

제시한 γ는 당시 정해둔 규칙의 선택 결과다. 보편적 최적값이나 test 기반 재선택이 아니다.

raw 통과 세 설정의 10개 출력 NRMSE를 함께 확인했다

모두 IC39 · 전체 10 ms · 수치는 무차원 비율

	T	H2	H	O	O2	OH	H2O	HO2	H2O2	N2
T/P10 γ=.1 장기	0.00241	0.0455	0.0743	0.0419	0.0127	0.061	0.00221	0.0382	0.0278	1.47e-16
P-only10 γ=.2 장기	0.00382	0.0392	0.0759	0.0198	0.0174	0.0285	0.0305	0.0199	0.0306	1.47e-16
P-only3 γ=.2 새 대조	0.00161	0.0469	0.0861	0.0401	0.0662	0.0137	0.0064	0.0121	0.0712	4.42e-16

같은 세 설정 순서	T/P10 γ=.1	P-only10 γ=.2	P-only3 새 대조
max |ΣY − 1|	0.0129	0.00641	0.0102

원소량 최대 이탈도 약0.0059-0.0116으로 남아 있다. 정확도 통과와 보존식 만족을 구분한다.

다중 스텝은 같은 시간에 수행할 수 있는 update 수가 훨씬 적다

장기 종료 시 누적 update · 누적 활성 시간 · 최종 LR · 종료 이유

방식	seed	누적 update	활성 시간	최종 LR	종료
단일	11	224,739	300.0 s	3.0e-05	시간상한
다중	11	37,224	271.1 s	1.0e-06	평탄
단일	22	220,796	300.0 s	2.7e-06	시간상한
다중	22	38,210	300.1 s	9.0e-06	시간상한
단일	33	225,572	300.0 s	1.0e-06	시간상한
다중	33	36,630	300.1 s	1.0e-06	시간상한

K64 누적 update: 2,929-3,563. 총 활성 학습 약29.5분 (평가·보고서 생성 시간 제외).

단기와 장기의 오차는 같은 IC 집합에서 비교했다

일반 ANN mean3 · worst9 = T·8반응종 NRMSE 중 최댓값

설정	공통 IC 수	단기 worst9	장기 worst9
raw ANN 단일	0	full10ms 비교 없음	full10ms 비교 없음
raw ANN 다중	1 (IC74)	62.688	57.656
repaired ANN 단일	18	6.431	4.702
repaired ANN 다중	12	23.411	23.281

IC가 여러 개면 worst9 중앙값. 모두 0.1 문턱과 비교하면 여전히 크다. 미완주는 0점으로 채우지 않았다.

원본 그림은 보존하고, 발표용 그림과 검색 목록을 별도로 만들었다

원본 1,283개 PNG/PDF/SVG 파일 + 발표용 16개 그림 묶음

발표할 때

이 PPTX / PDF → 한 장에 질문·관찰·다음 이유를 정리

질문을 받았을 때

gallery/index.html → 대표 결과·원본 전체 그림 검색

수치나 근거를 확인할 때

experiment_registry.csv / all_figures_index.csv / source manifest / IC별 NRMSE

파일 수를 실험 수로 세지 않았다. 발표용 그래프도 저장된 결과만 사용했으며 새 학습·평가는 하지 않았다.

main의 출발점과 bw의 변경 이력을 커밋으로 고정했다

더 자세한 실험 조건·수치·원본 경로는 발표자 노트와 동봉 목록에서 확인할 수 있다.

main 기준	e89c656 · GitHub commit
초기 DeepONet	3affe75 · GitHub commit
γ 장기 결과	7310311 · GitHub commit
시간 DeepONet 장기	53df7a5 · GitHub commit
일반 ANN 단기	dade4e6 · GitHub commit
일반 ANN 장기 · 최신	ad8c537 · GitHub commit

자료의 결론: 특정 한 조건의 성공을 전체 조건의 성공으로 확대하지 않고, 다음 실험의 가설을 좁혔다.