PUKYONG NATIONAL UNIVERSITY

수소 반응계
ANN·DeepONet 연구

Byeong Wan Ryu

2026. 11. 06.

초기 조건과 예측할 상태

IC = Initial Condition: 초기 온도 · 압력 · 당량비가 정해진 반응 조건 하나

초기 온도 T

900–1600 K
처음의 열 상태

압력 P

1–5 atm
정압 반응 조건

당량비 phi

0.5–2
연료 · 공기 혼합 비율

예측할 값 : 온도 T + 화학종 질량분율 9 개

H2 · H · O · O2 · OH · H2O · HO2 · H2O2 · N2

목표 : 같은 초기 조건의 Cantera 궤적을 NN 이 10 ms 까지 따라가게 한다 .

현재 상태에서 다음 상태로 전진하는 NN

2 μs 뒤를 한 번 예측하는 모델을 5,000 번 반복해 10 ms 까지 계산한다 .

현재 상태

T, Y, P 를
NN 입력으로 변환

→

NN 출력

정규화된 좌표에서
다음 상태의 증분

→

다음 상태

증분을 더한 뒤
물리 상태로 복원

예측한 다음 상태를 다시 입력 → 같은 과정을 계속 반복

한 번의 작은 오차도 반복 예측 과정에서 누적될 수 있다 .

학습 시작점을 골라도 정답은 항상 2 µs 뒤

전체 시계열에서 일부 입력 · 정답 쌍만 학습에 사용했다 . 아래는 선택 방식의 예시다 .

저장된 상태

0 µs	2 µs	4 µs	6 µs	8 µs

선택한 학습쌍 ①

0 µs 상태 입력 → 2 µs 상태 정답

선택한 학습쌍 ②

4 µs 상태 입력 → 6 µs 상태 정답

학습 54 조건 : 후보 270,000 쌍 → 선택 8,815 쌍

평형 구간의 중복을 줄이고 변화 구간을 남겼다 . 예측 간격은 2 µs 그대로다 .

온도와 농도의 크기 차이를 줄이는 전처리

학습에 넣기 전에 변환하고 , 학습 데이터의 평균 · 표준편차로 표준화한다 .

온도와 압력

온도 : T / 1000
압력 : log(P)
이후 학습 통계로 표준화

화학종 질량분율

질량분율 : Y^γ / γ
γ 에 따라 미량종의 스케일이 변함
이후 학습 통계로 표준화

표준화 = (변환한 값 – 학습 평균) / 학습 표준편차

평균 · 표준편차는 train 으로만 계산했다 . γ 를 바꾸는 실험은 뒤에서 비교한다 .

정확도는 예측이 끝난 뒤 전체 곡선으로 평가

매 적분마다 정확도 통과를 판정하지 않는다 . 저장된 같은 시각의 값들을 모아 계산한다 .

예측 도중 : 유효성 검사

음수 농도 ·NaN 등으로 중단되면 불완주
전체 10 ms 정확도 점수 없음

예측 종료 후 : 정확도 평가

같은 시각의 Cantera 와 NN 값 비교
변수마다 전체 시간 NRMSE 하나 계산

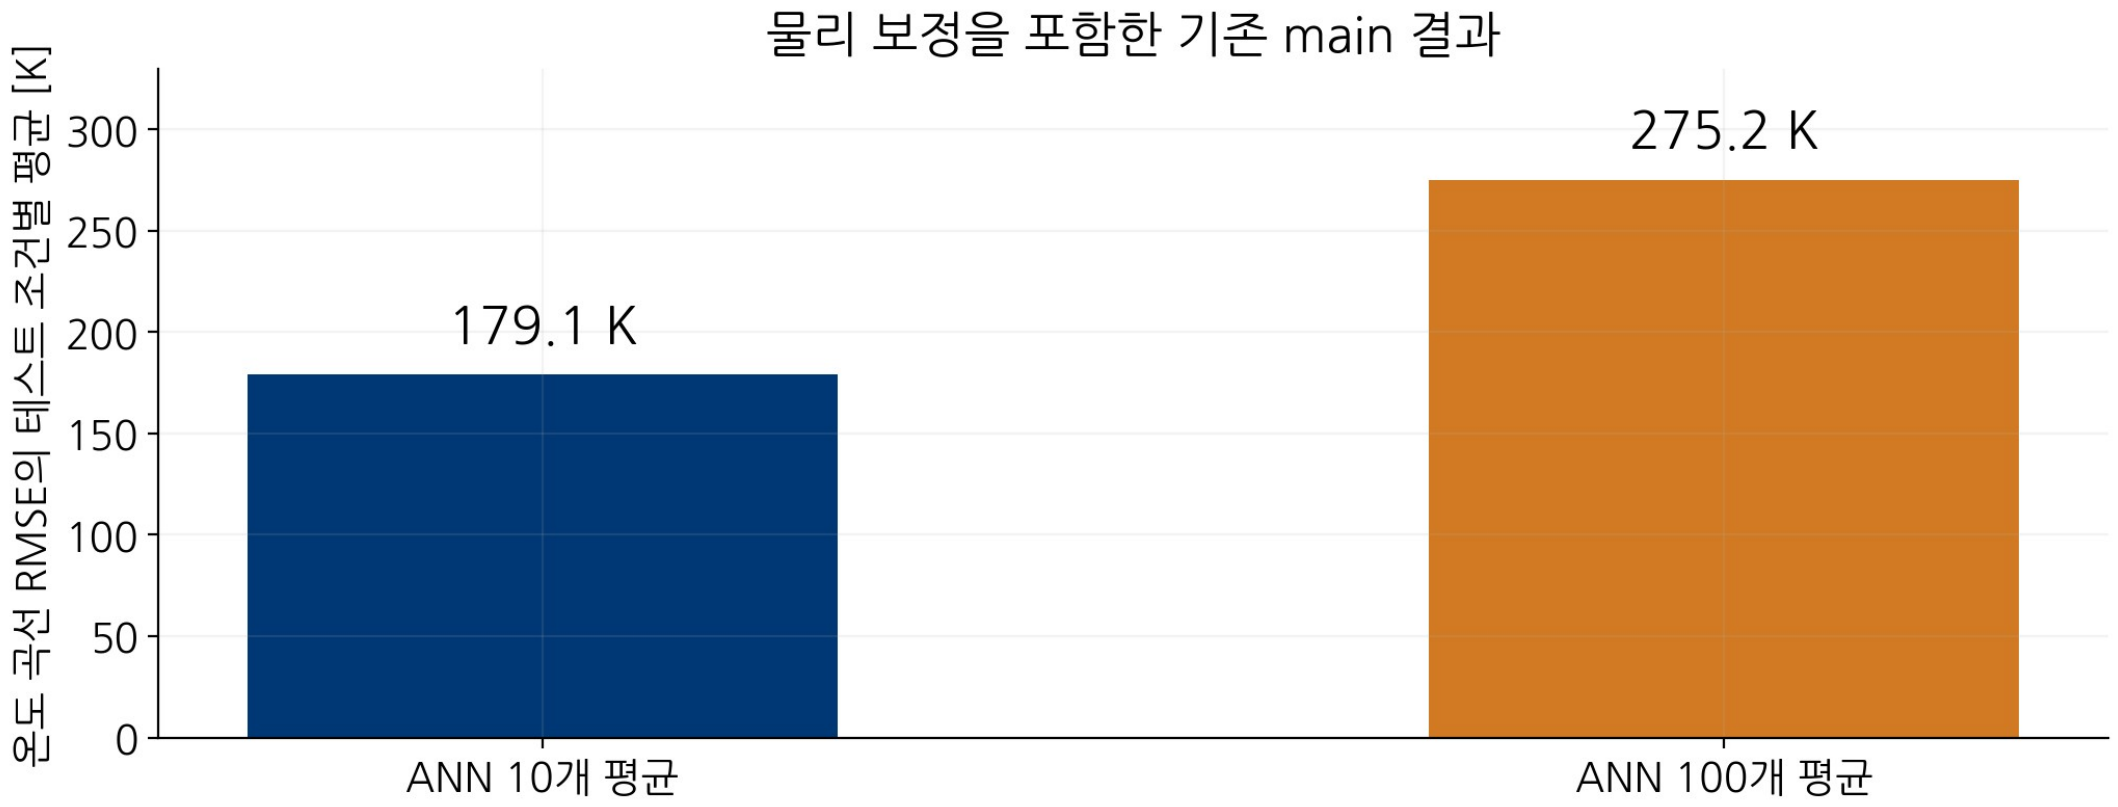
NRMSE = RMSE(Cantera, NN) / RMS(Cantera)

온도 + 8 반응종의 NRMSE 가 각각 모두 0.1 이하이면 통과
N2 와 초기 0.1 ms 구간은 별도로 확인

전체 곡선의 평균 오차 기준이다 . 모든 순간의 오차가 작다는 뜻은 아니다 .

main 의 출발점 : ANN 10 개와 100 개 평균

기존 100 개 모델 중 앞의 10 개를 부분집합으로 사용한 비교다 .



두 결과 모두 물리 보정 포함 . 다음에는 모델 수 대신 입력 구조를 바꿨다 .

bw 의 첫 비교 : 조건을 나누어 넣는 DeepONet

P-only 는 압력만 입력한다는 뜻이 아니다 . 압력을 trunk 에 따로 넣는 구조다 .

모델	Branch 입력	Trunk 입력
일반 ANN	현재 T·Y9·P 를 함께 MLP 에 입력	없음
P-only DeepONet	현재 T·Y9	현재 P
T/P DeepONet	현재 Y9	현재 T·P
T/P/phi DeepONet	현재 Y9	현재 T·P + 초기 phi

혼합 결과는 같은 현재 상태에서 ANN10 개 + DeepONet10 개의 후보를 평균한다 .

구조를 바꾸고 추가 학습한 초기 결과

물리 보정 없는 장기 결과 . 완주 수와 정확도 통과 수를 따로 읽어야 한다 .

장기 평가 설정	완주 / 18	정확도 통과 / 18
기존 ANN10	2	0
P-only10	6	0
ANN10 + P-only10	9	0
T/P10	12	1 (IC39)
ANN10 + T/P10	6	0
T/P/phi10	7	0
ANN10 + T/P/phi10	11	0

입력 구조와 학습 시간만으로 부족했다 . 다음에는 물리 정보를 loss 에 넣었다 .

Soft constraint: 학습 손실에 원소량 벌점 추가

λ 는 원소 보존 벌점을 얼마나 강하게 반영할지 정하는 가중치다 .

학습 loss = 기존 증분 MSE + λ × 다음 상태의 원소량 오차

Soft constraint

학습 중 오차에 벌점을 더함
그 손실을 역전파해 가중치 수정
H·O·N 원소량 차이에 L1 벌점

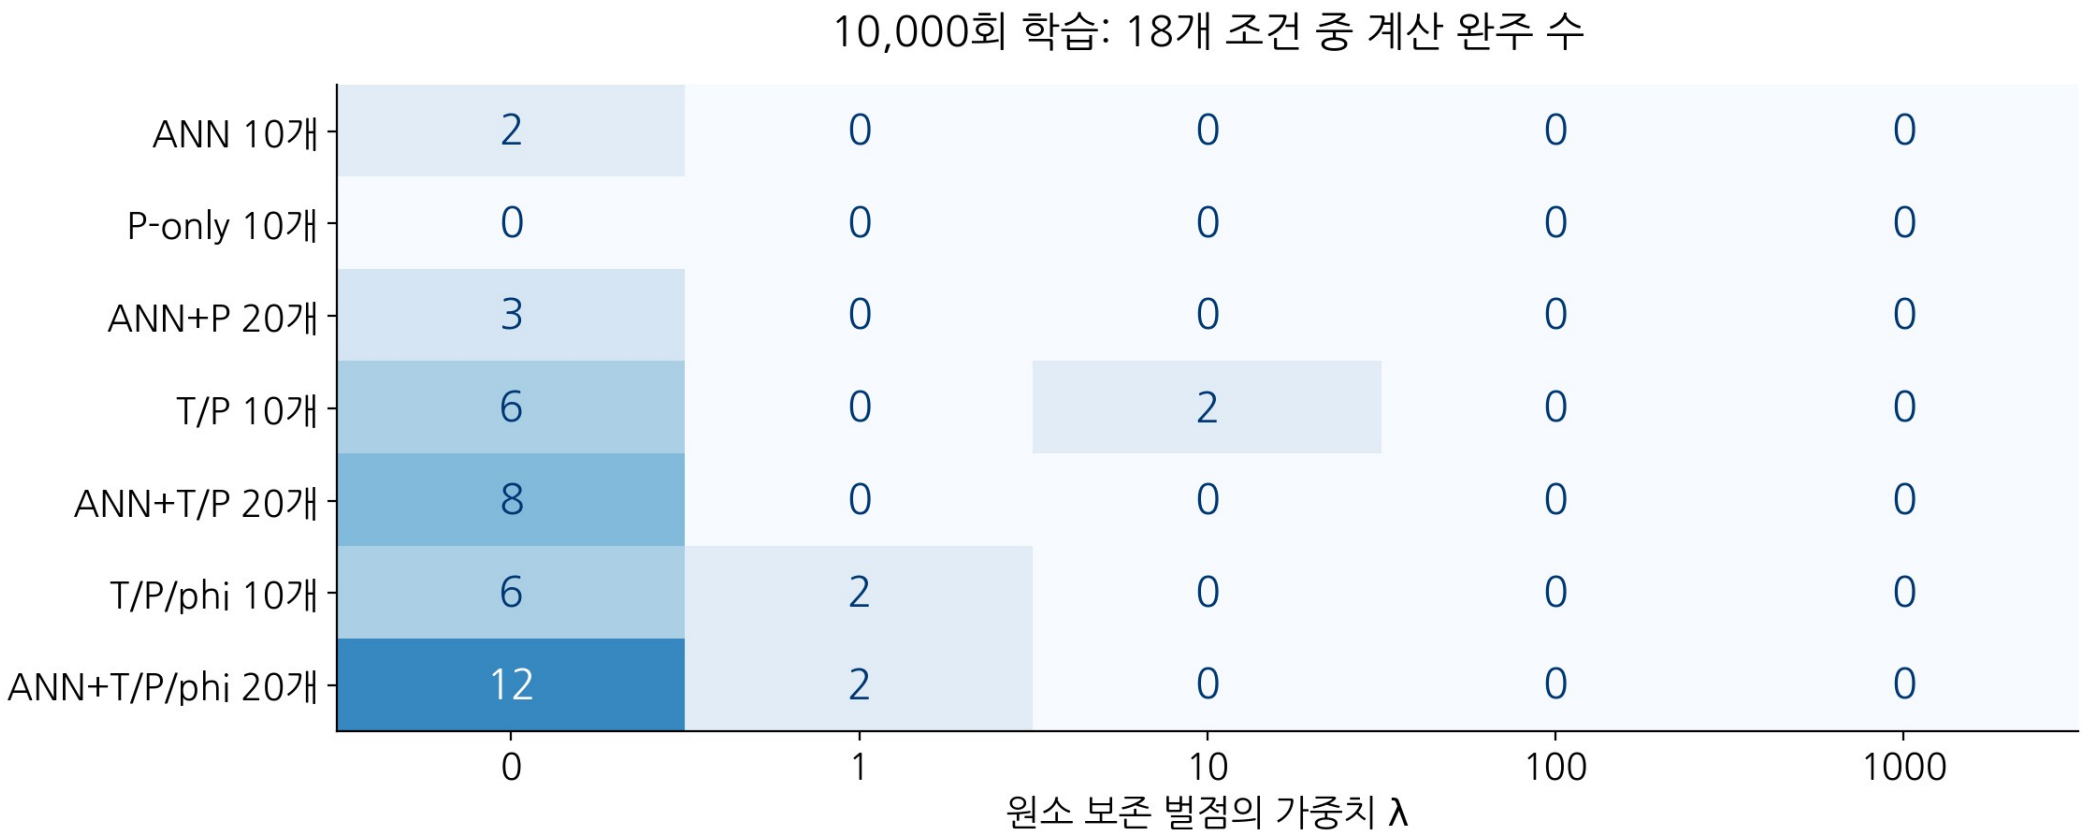
물리 보정 (repaired)

예측 중 나온 상태를 수정함
원소량과 엔탈피 등에 맞춰 복원
학습 벌점과 별도 기능

NN 출력은 계속 상태 증분이다 . 반응률을 직접 출력하도록 바꾼 실험은 아니다 .

λ = 1·10·100·1000 을 비교한 결과

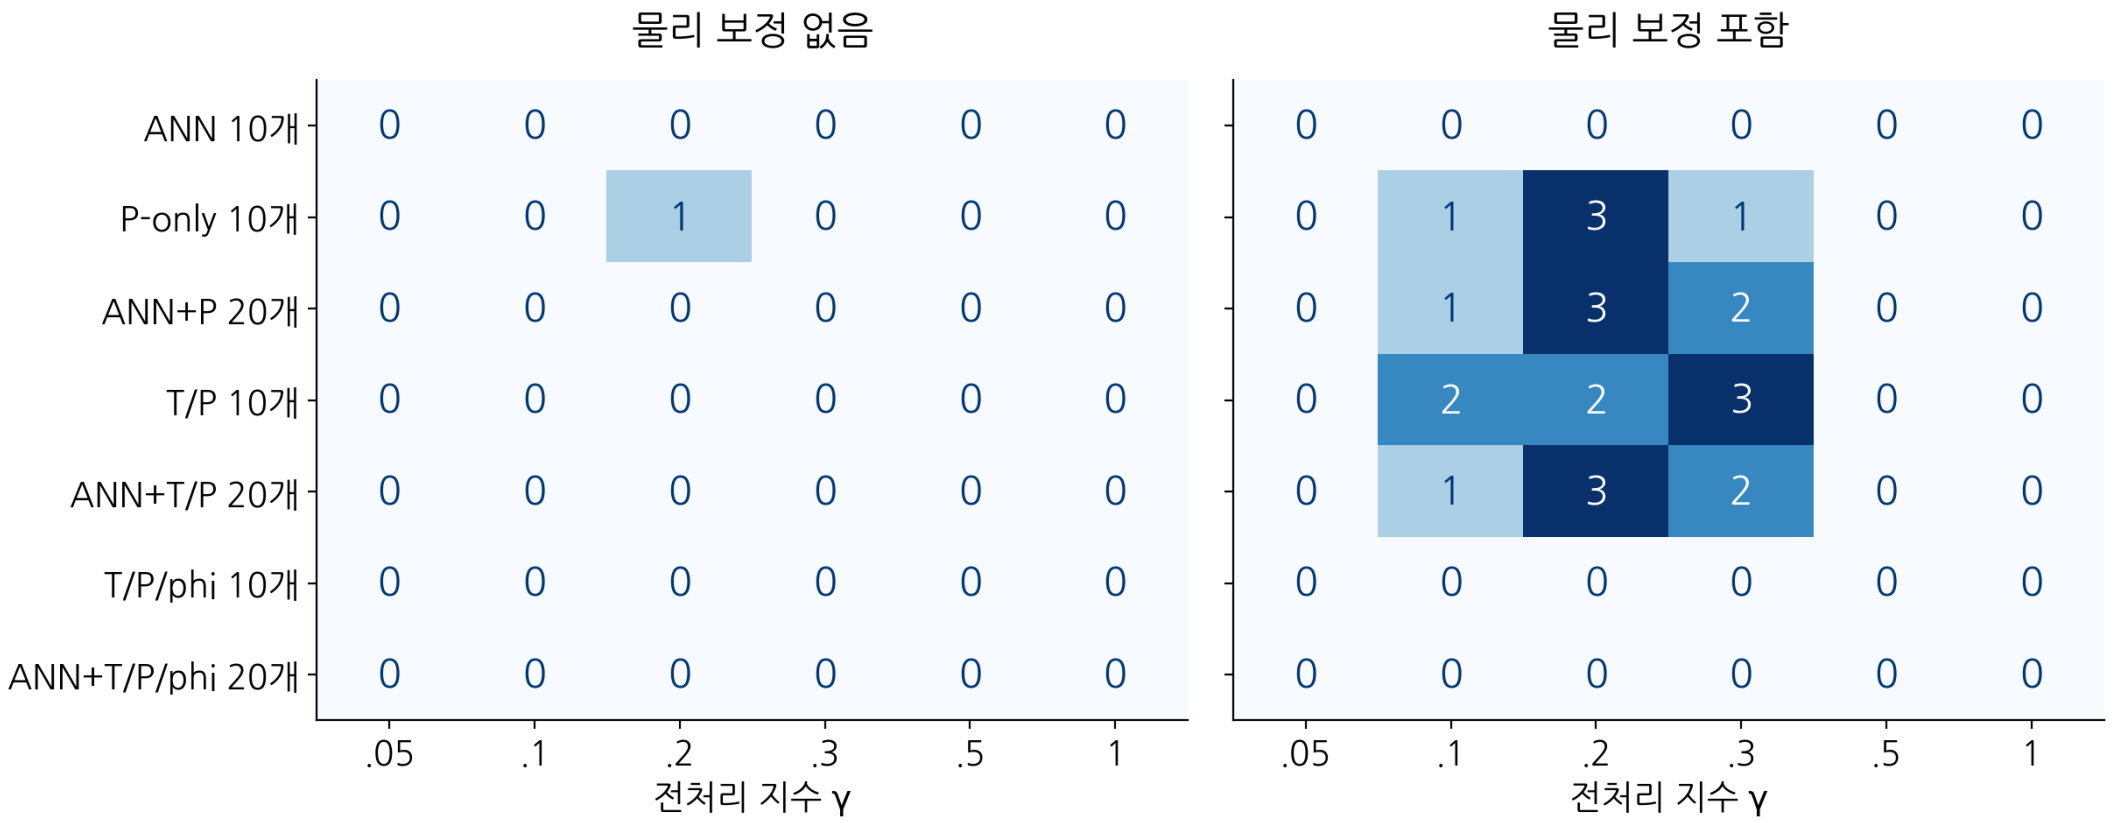
γ=.1 고정 . 단기는 모델마다 10,000 회 가중치를 수정하는 학습을 수행했다 .



추가 학습에서도 새 raw 정확도 통과는 0. 이후 soft 항을 빼고 전처리를 바꿨다 .

Box–Cox 전처리 지수 γ 를 바꾼 결과

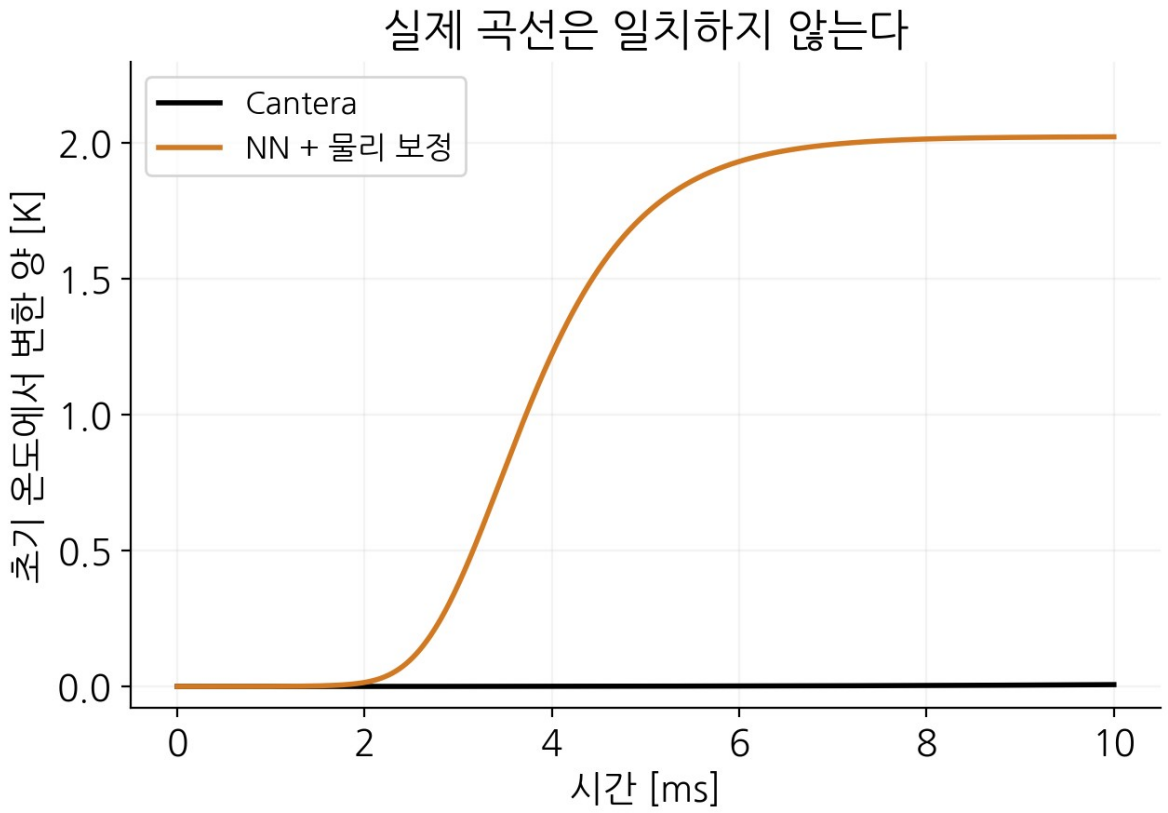
γ=.05/.1/.2/.3/.5/1, 물리 벌점 없이 MSE 만 학습 . 아래는 장기 정확도 통과 수다 .



raw 통과는 P-only γ=.2 의 IC39 하나 . γ 변경만으로 넓은 정확도를 얻지는 못했다 .

작은 온도 NRMSE 와 곡선의 일치는 다르다

IC07, γ=.2, ANN+P 장기 , 물리 보정 포함 . 곡선 자체는 잘 맞지 않는 사례다 .



작게 나온 것은 온도 NRMSE 수치

온도 RMSE 1.50 K

기준 온도 RMS 930.60 K

1.50 / 930.60 = 0.00161

같은 예측의 화학종 NRMSE

H2O: 781 OH: 754

작게 나온 것은 온도 점수다 . 온도 변화 곡선도 다르고 , 화학종 오차는 매우 크다 .

물리 보정은 계산을 돕지만 정확도를 보장하지 않는다

이후 결과에서 보정 없음 (raw) 과 보정 포함 (repaired) 을 계속 구분한다 .

역변환 범위 조정

복원할 수 없는 입력 범위를
허용 범위로 제한

비음수 · 원소량 투영

음수 농도와 원소량을
물리 조건에 맞춰 조정

엔탈피로 온도 복원

화학종 상태와 엔탈피가
맞도록 온도를 계산

유효한 후보 평균

앙상블의 유효 후보만 평균하고
평균한 상태도 다시 보정

완주는 10 ms 까지 계산됐다는 뜻이다 . 반응 속도 · 점화 시각의 정확도는 별도다 .

과거 raw 결과에서 통과한 조건은 IC39 하나

저장된 전체 10ms 평가를 다시 조사했다. 세 모델 설정의 성공이 같은 조건에 집중됐다.

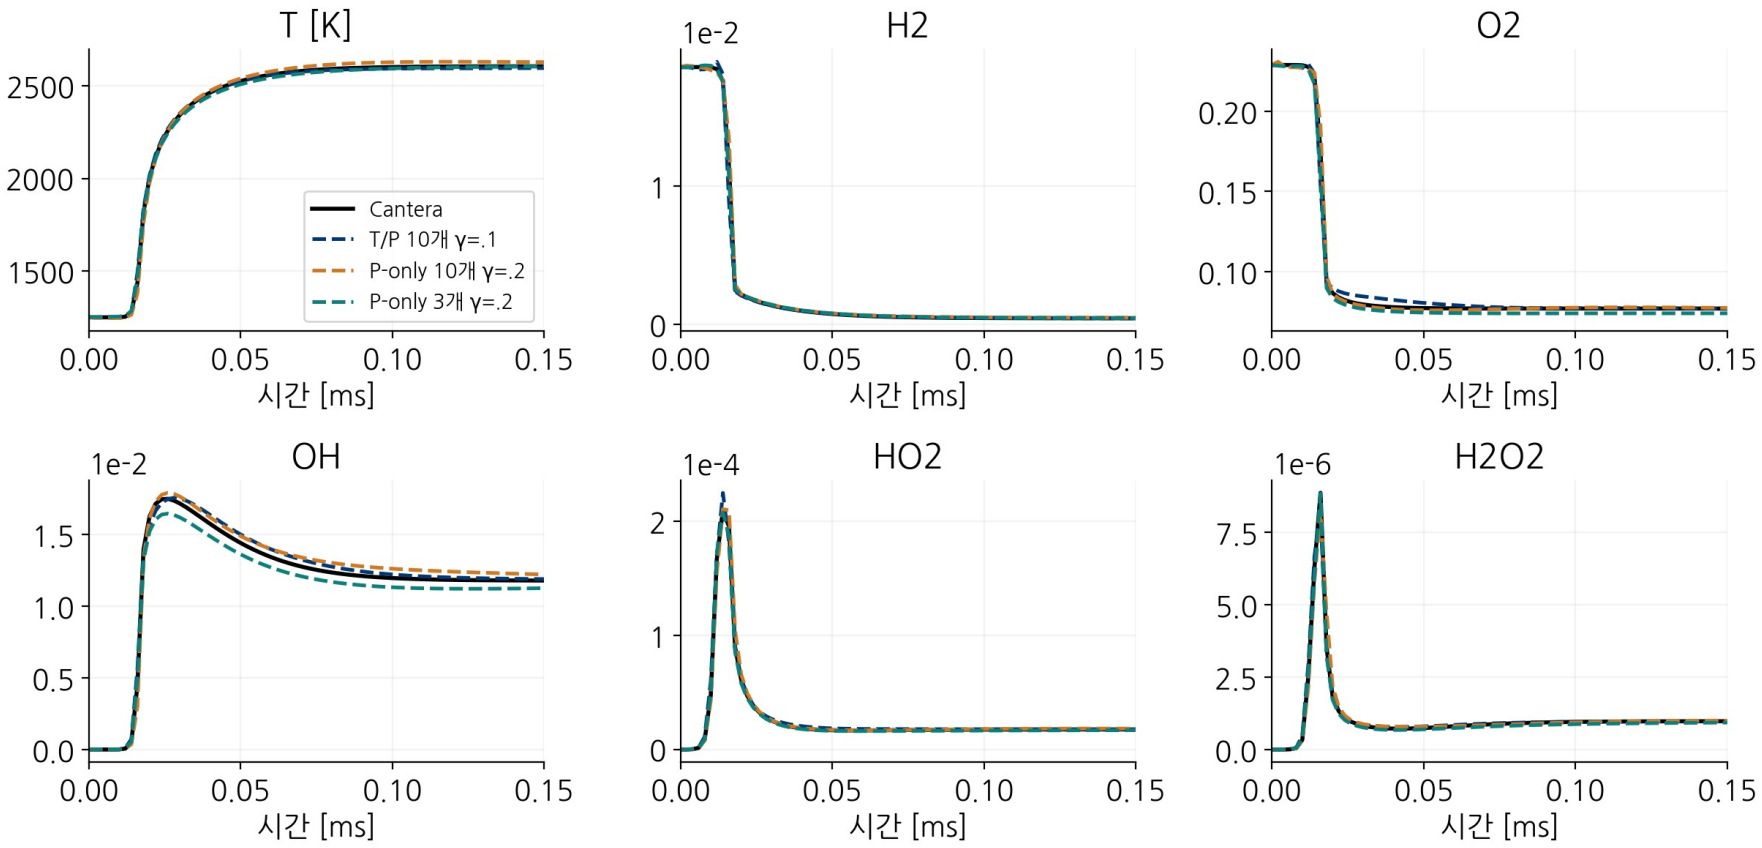
물리 보정 없는 설정	전체 10ms 최대 NRMSE	초기 0.1ms 최대
T/P 10 개 평균 · γ=.1 장기	0.0743	0.0975
P-only 10 개 평균 · γ=.2 장기	0.0759	0.1347
P-only 3 개 평균 · γ=.2 새 대조	0.0861	0.0558

최대 NRMSE = 그 조건의 출력 변수별 NRMSE 중 가장 큰 값

세 설정이 통과했어도 서로 다른 테스트 조건은 IC39 하나뿐이다.

IC39 에서 실제로 맞았던 점화 곡선

초기온도 1250.05 K, 압력 2.297 atm, phi=.646. 아래는 점화 구간을 확대했다 .



전체 10ms 통과와 초기 점화 구간의 일치는 별도로 확인했다 . 다른 17 조건의 성공은 아니다 .

IC39 통과 설정의 변수별 NRMSE

온도만 통과한 것이 아니라, 각각의 화학종 오차도 함께 확인한 표다.

설정	T	H2	H	O	O2	OH	H2O	HO2	H2O2	N2
T/P10 γ=.1	0.002	0.046	0.074	0.042	0.013	0.061	0.002	0.038	0.028	≈0
P-only10 γ=.2	0.004	0.039	0.076	0.020	0.017	0.028	0.030	0.020	0.031	≈0
P-only3 γ=.2	0.002	0.047	0.086	0.040	0.066	0.014	0.006	0.012	0.071	≈0

세 설정의 최대 | 질량분율 합 − 1|: 0.0129 / 0.00641 / 0.0102

N2 의 ≈ 0 은 약 10^-16 수준이다. 작은 NRMSE 와 정확한 물리 보존은 별도 조건이다.

다음 시도 : 시간 간격과 다중 스텝 학습

한 번의 예측을 배우는 것과 , 자기 예측을 이어가며 배우는 것을 비교했다 .

시간 간격 DeepONet

입력에 “앞으로의 간격” tau 추가
2 / 4 / 8 / 16 μs 뒤 상태를 학습

현재 상태에서 지정 간격만큼 전진
평가에서는 tau=2 μs 사용

다중 스텝 DeepONet

2 μs 예측을 K 번 자기 입력으로 반복
1~K 번째 상태의 오차를 모두 학습

K=64 면 학습에서 128 μs 까지 추적
평가 간격은 계속 2 μs

간격 입력 모델과 여러 번 되먹이는 학습 방식은 서로 다른 접근이다 .

다중 스텝 학습 순서와 비교 기준

여기부터 단기는 처음 150 초 , 장기는 최대 150 초 추가 학습이다 . 앞선 10k 회 기준과 다르다 .

단기 150 초를 네 구간으로 나눔 → 장기에는 K=64 유지

K=1	K=4	K=16	K=64

학습 계산 시간

실제 학습 연산 시간
준비 · 테스트 · 보고서 제외
기존의 “활성 시간”

서로 다른 학습 A/B/C

난수 설정을 달리해 3 번 학습
초기 가중치 등이 달라짐
기존의 “ seed 11/22/33”

3 개 모델 평균

같은 현재 상태에
세 모델의 다음 상태 후보를
평균해 계속 전진

동일한 시간 상한으로 비교했다 . K 가 커지면 같은 시간에 가능한 학습 회차는 줄어든다 .

시간 · 다중 스텝 DeepONet 의 단기 · 장기 결과

각 방식 3 개 모델 평균 , γ=.2. 먼저 물리 보정 없는 결과를 비교한다 .

방식	완주 : 단기 → 장기	정확도 통과 : 단기 → 장기
단일 스텝 대조군	7 → 9	0 → 1
시간 간격 입력	0 → 0	0 → 0
다중 스텝 학습	14 → 13	0 → 0

물리 보정 포함 : 세 방식 모두 18/18 완주
정확도 통과는 대조군 3→2, 새 두 방식은 0

다중 스텝은 완주를 늘렸지만 정확한 새 테스트 조건을 추가하지는 못했다 .

일반 ANN 에서도 다중 스텝을 별도 비교

이번 모델은 branch/trunk 가 없는 일반 MLP 다 . 앞 실험의 DeepONet 과 구분한다 .

입력 11 → 은닉층 64 → 64 → 64 → 출력 10

단일 스텝 ANN

2 μs 뒤 정답 한 개를 맞추는 loss
학습 A/B/C 로 각각 수행
총 3 개 모델

다중 스텝 ANN

자기 예측을 K 번 이어가며 학습
학습 A/B/C 로 각각 수행
총 3 개 모델

같은 A/B/C 의 두 방식은 초기 가중치를 같게 했다 . γ=.2 와 시간 상한도 유지했다 .

일반 ANN 의 단기 · 장기 결과

각 방식 3 개 모델 평균 . 앞의 기존 ANN10 과는 모델 수 ·γ· 학습 예산이 다른 실험이다 .

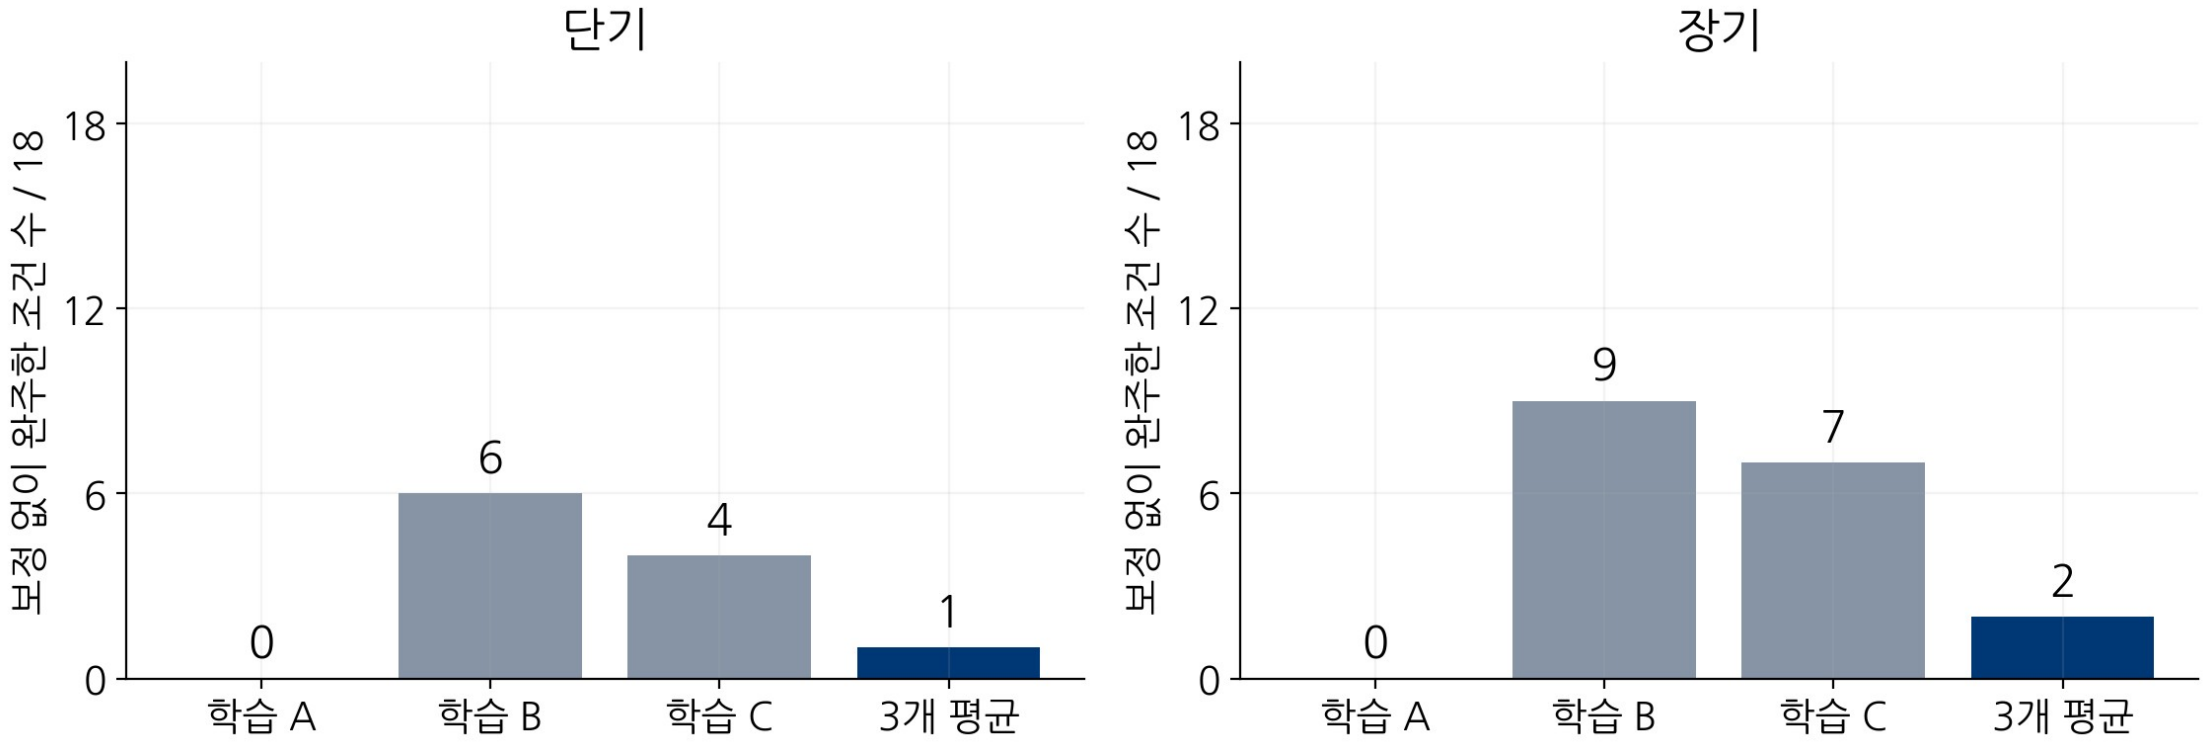
물리 보정 없음	완주 : 단기 → 장기	정확도 통과 : 단기 → 장기
단일 스텝 ANN	0 → 0	0 → 0
다중 스텝 ANN	1 → 2	0 → 0

물리 보정 포함	완주 : 단기 → 장기	정확도 통과 : 단기 → 장기
단일 스텝 / 다중 스텝	18→18 / 13→14	둘 다 0 → 0

일반 ANN 도 일부 더 완주했지만 , 단기 · 장기와 개별 모델 모두 정확도 통과는 없었다 .

난수 설정을 바꾸면 결과가 얼마나 다른가

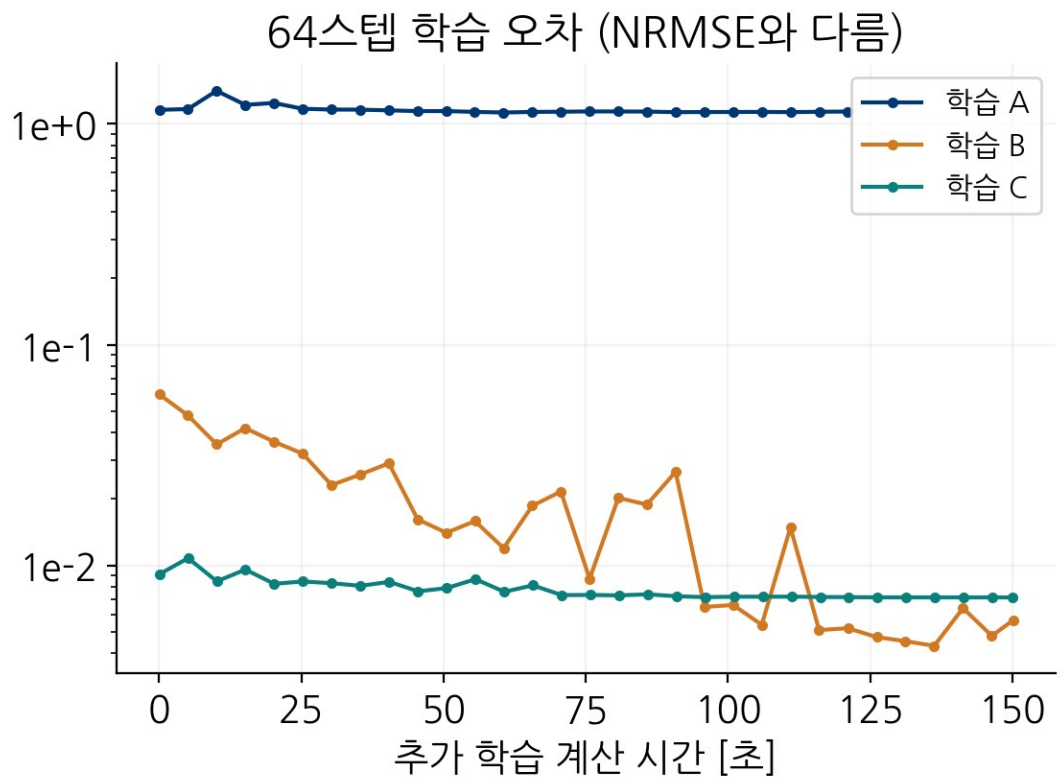
일반 ANN 다중 스텝의 학습 A/B/C 와 3 개 모델 평균을 비교한다 .

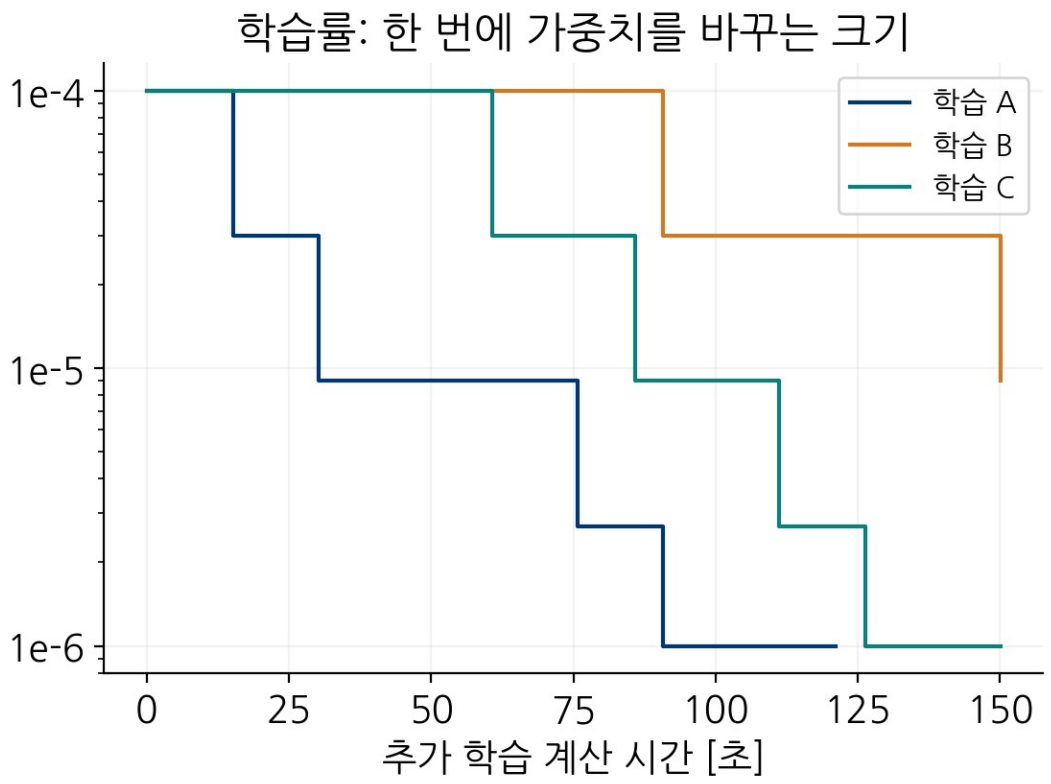


같은 학습 조건이어도 결과 편차가 컸다 . 3 개 평균이 최선의 단일 모델보다 좋지는 않았다 .

학습 오차의 평탄과 예측 정확도는 별개

다중 스텝 장기 학습은 K=64 로 고정했다 . 왼쪽 학습 오차는 NRMSE 가 아니다 .





학습 A 는 평탄 종료했지만 정확도 통과 0. 장기 6 개 중 평탄 1 개 , 시간상한 5 개였다 .

학습 회차를 세는 방법 : update

1 update = 한 배치의 오차를 역전파해 NN 가중치를 한 번 수정하는 것

방식	학습	단기 + 장기 총회차	총 학습 계산 시간	종료
단일	A	224,739	300.0 초	시간상한
다중	A	37,224	271.1 초	평탄
단일	B	220,796	300.0 초	시간상한
다중	B	38,210	300.1 초	시간상한
단일	C	225,572	300.0 초	시간상한
다중	C	36,630	300.1 초	시간상한

같은 150 초 상한이어도 다중 스텝 한 회차가 더 비싸므로 수행한 회차 수는 적다 .

단기 · 장기 오차는 같은 조건끼리 비교한다

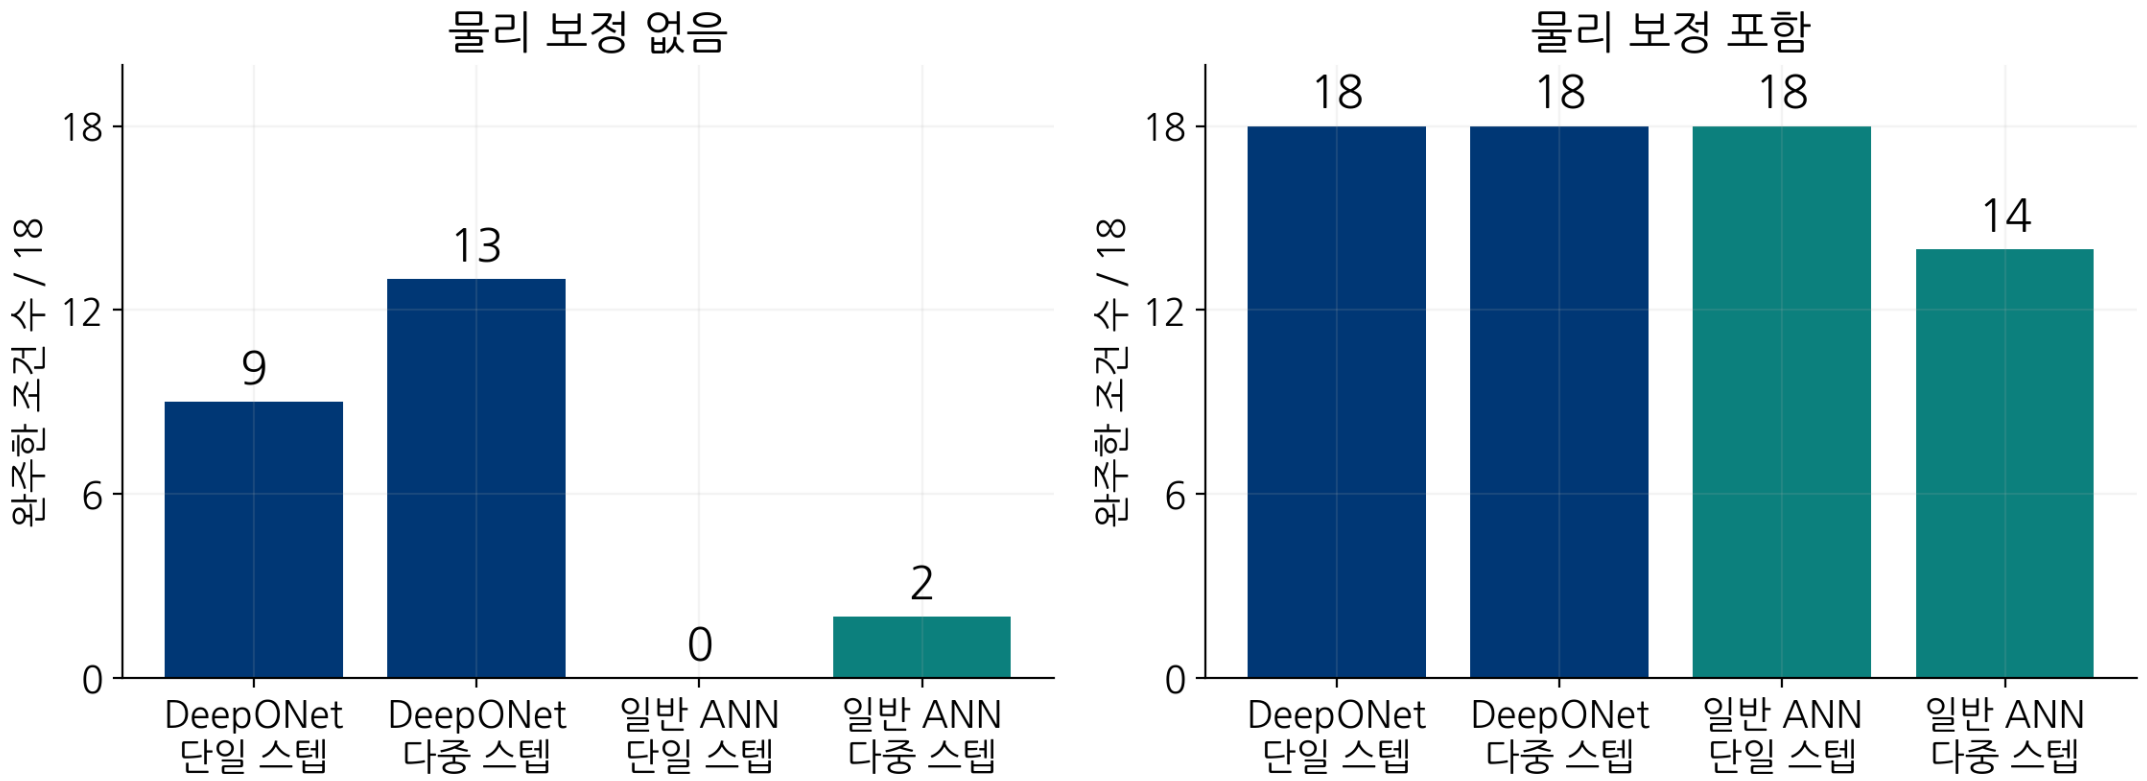
각 조건에서 9 개 변수의 NRMSE 중 가장 큰 값을 고르고, 조건이 여러 개면 그 중앙값을 쓴다.

일반 ANN 설정	공통 조건 수	단기 오차	장기 오차
보정 없음 · 단일	0	전체 10ms 점수 없음	전체 10ms 점수 없음
보정 없음 · 다중	1 (IC74)	62.688	57.656
보정 포함 · 단일	18	6.431	4.702
보정 포함 · 다중	12	23.411	23.281

기존 worst9 의 뜻을 풀어 썼다. 값이 줄어도 0.1 보다 훨씬 커서 정확도 통과는 아니다.

최신 DeepONet 과 일반 ANN 의 결과 비교

γ=.2, 각 3 개 평균 , 단기 150 초 + 장기최대 150 초 . 아래 막대는 정확도가 아니라 완주 수다 .



raw 정확도 통과 : DeepONet 단일 1, 나머지 0. 다중 스텝의 높은 완주가 정확도는 아니다 .

현재까지 확인한 결과와 다음 검증

결과를 정리한 뒤 , 다음 실험에서 분리해 확인할 질문을 남긴다 .

실제로 확인한 것

모델 수 · 구조 ·loss· 전처리를 비교
다중 스텝에서 일부 완주 증가

보정 없는 정확도 통과는
여전히 IC39 한 조건에 집중

다음에 검증할 질문 (미실행)

K 별 학습 시간 배분을 바꾸면 ?
화학종 오차를 loss 에 더 맞추면 ?

자기 예측 상태의 분포 이탈 진단
새 테스트 조건에서 최종 확인

다음 목표는 “끝까지 계산”과 “여러 조건의 정확한 반응 예측”을 함께 달성하는 것이다 .